班　级　220452

学　号　22049200392

西安电子科技大学

本科毕业设计论文

题　　目　融合神经网络和卡尔曼滤波的混合模型状态估计

学　　院　机电工程学院

专　　业　测控技术与仪器

学生姓名　王苏棋

导师姓名　董春云

摘　要

关键词：神经网络　　卡尔曼滤波　　状态估计

ABSTRACT

Keywords: Neural Networks Kalman Filter State Estimation

目 录

第一章 绪论 **1**
1.1 选题背景与研究意义 1
1.2 国内外研究现状 2
1.2.1 视觉目标检测与跟踪算法研究现状 2
1.2.2 状态估计与传统滤波算法的局限性 3
1.2.3 人工智能与滤波算法的深度融合 3
1.3 论文研究工作及安排 4
第二章 相关理论与技术基础 **7**
2.1 YOLOX 算法原理 7
2.1.1 解耦头设计 7
2.1.2 无锚框与 SimOTA 策略 7
2.2 多目标跟踪框架 7
2.2.1 ByteTrack 算法流程描述 7
2.2.2 算法与卡尔曼滤波的关系 8
2.3 经典状态估计理论 8
2.3.1 数学模型描述 8
2.3.2 递归滤波过程 8
2.3.3 传统算法的局限性分析 9
第三章 融合神经网络与滤波的算法设计 **11**
3.1 混合模型总体架构设计 11
3.2 KalmanNet 状态估计网络设计 11
3.2.1 多维输入特征提取 11
3.2.2 网络架构选择与设计 12
3.2.3 基于网络输出的增益残差修正 12
3.3 模型训练策略与损失函数设计 13
3.3.1 有监督损失函数 13
3.3.2 由短及长的递进式训练策略 13
第四章 实验结果与分析 **15**

4.1 实验环境与数据集 15
4.2 评价指标 15
4.3 实验结果与分析 15
4.3.1 GRU 架构选择 15
4.3.2 训练策略分析 17
4.3.3 输入特征组合消融实验 19
4.4 YOLOX 检测器训练结果 20
4.5 导弹数据集跟踪性能评估与效果展示 20
致谢 23
参考文献 25

第一章　绪论

1.1　选题背景与研究意义

现代军事技术持续演进，战场对抗强度不断升级。在这一背景下，高机动飞行器凭借超高突防速度与精确打击效果，在现代战争体系中占据了核心地位。此类目标能够执行远程精确打击与战术突防等多种关键任务，对战场态势具有决定性影响。随着推进技术与气动布局不断演进，高机动导弹正朝着更高马赫数、更强隐身性能方向发展，给国家空天防御体系及关键战略设施保护带来了严峻技术挑战。

面对此类具备极强毁伤能力和战略威慑力的目标，构建多层次、全方位的空天防御体系已成为各国战略防御的核心任务。在反导作战体系中，中段反导系统（Mid-course Defense System）占据着至关重要的地位。导弹中段飞行处于大气层外真空环境，持续时间最长，飞行轨迹相对稳定，是实施拦截的最佳时机。现代中段反导体系通常采用天基预警探测与拦截弹精确打击的协同模式，利用部署在特定轨道上的预警卫星星座对弹道导弹进行全时段、全疆域监控。卫星感知模块在导弹进入弹道中段后持续进行特征识别与轨迹跟踪，经高带宽数据链将目标状态向量实时下传，引导动能拦截器完成精确碰撞。

在天基拦截系统感知模块设计中，计算机视觉与光学探测技术是实现目标识别的核心手段。在深空背景下，传统雷达系统受限于卫星平台载荷体积与功耗限制，加之空间电磁环境复杂，难以实现高分辨率特征提取。相比之下，天基视觉感知方案具备明显优势。导弹进入弹道中段后发动机关机，红外特征随之显著减弱，此时光学手段反而成为更可靠的探测途径。视觉传感器获取的目标光学图像能够实现精确三维空间定位，在面对金属箔条、气球诱饵等复杂干扰时也具备较强的真假弹头辨识能力。因此，以计算机视觉技术为基础的卫星识别系统是天基中段反导网络获取目标观测数据的重要来源。

然而，获取高质量视觉观测数据仅是拦截任务的前置条件。系统跟踪效果更根本地取决于对目标高非线性动态轨迹的连续状态估计与预测能力。高机动导弹在突防过程中常采取不可预测的变轨机动，运动模型非线性极强。同时天基光学传感器在极远距离下提取的视觉量测特征，不可避免地包含由成像极限和前端检测算法引入的复杂量测噪声。上述两类问题共同导致系统难以满足线性高斯假设，

传统卡尔曼滤波（Kalman Filter，KF）在处理此类时序数据时极易产生模型失配，进而引发轨迹预测发散与滞后。

近年来，深度神经网络（Deep Neural Network，DNN）技术日趋成熟，为状态估计问题提供了新的解决思路。将神经网络的非线性拟合能力引入卡尔曼滤波框架，构建混合驱动架构，成为当前的主流研究方向之一。混合驱动架构的核心在于保留卡尔曼滤波的状态更新结构，以神经网络替代基于固定协方差矩阵的增益计算环节。神经网络通过学习历史观测残差序列隐式感知系统动力学偏差，进而输出最优卡尔曼增益，实现对量测误差与机动模型失配的自适应补偿。KalmanNet 是此类方法的典型代表，以递归神经网络（Recurrent Neural Network，RNN）实时计算增益矩阵，在未知噪声统计特性条件下仍能维持稳定的估计精度。在视觉多目标跟踪领域，ByteTrack 等算法已将卡尔曼滤波作为运动预测的核心组件。然而固定参数设置难以适应高机动目标的快速状态变化，这一局限性在天基观测场景中尤为突出。将自适应卡尔曼滤波模块集成至 ByteTrack 框架并针对高机动特性优化，能够在视觉观测质量下降时维持轨迹连续性与精确性，是解决高机动目标中段连续跟踪难题的重要技术路径，也代表了未来高精度空天防御技术的重要发展方向。

1.2 国内外研究现状

1.2.1 视觉目标检测与跟踪算法研究现状

计算机视觉技术近期在目标检测与跟踪任务中进展显著。单阶段检测方法中 YOLOX 算法作为 YOLO 系列重要演进版本展现出卓越性能。传统检测范式如 YOLOv4 与 YOLOv5 主要采用基于锚框机制。此类方法需要预先设定大量敏感超参数。相应地模型面对尺度与形状各异目标时泛化能力受到限制。基于此 YOLOX 算法引入无锚框机制。系统通过像素级回归策略直接预测目标边界框。此举显著降低计算复杂度并提升检测灵活性。此外 YOLOX 采用解耦头结构。该结构从特征层面分离分类与定位任务。相应地解耦操作有效缓解两类任务特征耦合冲突。系统配合 SimOTA 动态标签分配策略在保证实时推理速度前提下实现复杂背景下高机动目标鲁棒检测。为了提升这些检测器在实际战场环境下可靠性，研究人员不断优化损失函数与正负样本采样逻辑。

高质量检测器能够提供精确单帧目标定位结果。然而构建时间序列连续运动轨迹必须借助多目标跟踪技术。现代多目标跟踪框架普遍遵循先检测后跟踪技术

路径。该路径性能高度依赖前端检测器精度。早期 SORT 算法利用卡尔曼滤波结合匈牙利算法。系统实现轻量级目标关联并具备较高运行效率。随后 DeepSORT 算法在原有基础上引入深度外观特征模块。该算法增强遮挡场景下身份维持能力。此外算法在拥挤场景中易受干扰且计算开销较大。基于此 ByteTrack 算法提出基于检测置信度分级关联策略。系统通过保留并二次利用低分检测框恢复被错误过滤目标信息。相应地算法有效克服目标快速运动或相互遮挡时因置信度下降导致轨迹断裂问题。ByteTrack 显著提升跟踪连续性。目前该算法已成为该领域重要基准方案。研究人员认为这种策略能够有效解决机动目标在复杂背景中特征不稳定难题。

1.2.2　状态估计与传统滤波算法的局限性

实现精确平滑连续轨迹预测需要深入掌握状态估计理论。导弹等高速机动对象应用场景对该理论要求极高。卡尔曼滤波作为处理线性高斯系统状态估计问题最优估计器应用广泛。系统采用预测与更新递归闭环机制。相应地卡尔曼增益对预测值与量测值进行加权融合。该过程得到最优后验状态估计。然而标准卡尔曼滤波要求系统满足线性叠加原理。此外过程噪声与量测噪声必须服从高斯分布。这种数学假设在理想实验环境下表现良好。

物理系统中普遍存在非线性特征。学术界针对此问题发展出扩展卡尔曼滤波与无迹卡尔曼滤波等改进方法。然而上述变体本质上仍属于模型驱动方法。相应地算法性能高度依赖精确系统动力学方程。此外系统需要先验已知过程噪声协方差矩阵与量测噪声协方差矩阵。目标进行未知强机动飞行时模型参数与实际动态产生失配。基于此固定参数滤波器难以及时响应动态变化。相应地系统极易导致估计精度下降甚至产生发散现象。由于高机动目标运动轨迹极为复杂，传统线性化近似方法往往难以覆盖真实物理演化过程。工程实践中往往发现这种参数敏感性是导致跟踪失败核心诱因。

1.2.3　人工智能与滤波算法的深度融合

人工智能与滤波结合技术路线近期成为研究热点。该方案旨在解决传统模型驱动方法局限性。长短期记忆网络通过精心设计门控机制有效解决长序列训练梯度消失问题。相应地网络具备强大时序特征提取与历史信息记忆能力。系统常利用此类模型对复杂非线性运动残差进行建模。此外该方式能够有效补偿传统滤波器系统误差。通过引入这些时序处理单元，系统对于目标未来位置预测会变得更

加可靠。

KalmanNet 作为人工智能赋能滤波领域代表性工作提出深度融合混合驱动架构。该方法保留卡尔曼滤波中物理意义明确状态更新结构。此外系统利用递归神经网络替代传统算法中基于固定协方差矩阵计算增益过程。KalmanNet 通过数据驱动方式根据输入观测残差序列实时感知系统模型失配程度。相应地网络动态输出最优增益矩阵。该方法有效摆脱对精确噪声统计特性强依赖。基于此滤波器获得较强非线性适应能力。顺应这一研究趋势在 ByteTrack 框架中集成自适应卡尔曼滤波模块具有重要意义。针对导弹目标高机动特性进行专项优化能够提升复杂对抗环境下估计精度。相应地该方案可实现更精准鲁棒目标状态估计。这在工程实践中展现出巨大研究价值。

1.3 论文研究工作及安排

本文研究内容主要为构建一种融合深度学习与经典滤波理论的混合估计系统。系统首先利用 YOLOX 算法实现前端目标检测。随后算法基于 ByteTrack 框架完成多目标关联。核心环节引入 KalmanNet 辅助标准卡尔曼滤波。该模型通过提取新息残差（F_2）与状态更新差值（F_4）实现增益自适应修正。相应地系统能够降低对 $\boldsymbol{Q}$、$\boldsymbol{R}$ 矩阵人工设定敏感性。此外研究工作涉及系统架构设计与模型训练策略优化。本文旨在确保导弹目标在复杂对抗场景下依然具备稳定跟踪性能。最终内容通过仿真实验验证算法可行性。

本文共分为五个章节。各章节具体研究工作安排如下：

第一章是绪论。内容首先阐述高机动导弹识别跟踪研究意义。文章调研国内外视觉检测与状态估计研究现状。此外章节指出传统滤波算法在非线性场景中存在局限性。相应地内容引出人工智能与滤波算法融合必要性。随后内容明确本文研究工作安排。

第二章介绍相关理论基础。内容推导 YOLOX 检测器原理。文章介绍 ByteTrack 分级关联流程。相应地章节给出标准卡尔曼滤波数学模型。此外内容重点分析模型参数失配对跟踪稳定性产生影响。基于此部分内容为后续引入 KalmanNet 修正机制提供理论依据。

第三章阐述混合驱动算法具体设计。系统详细论述 KalmanNet 轻量化网络架构。内容给出 F_1 至 F_4 四类差分特征数学定义。基于此算法选取核心特征组合输入网络。此外章节介绍端到端训练损失函数设计。相应地内容说明如何通过残差

修正项 $\Delta \boldsymbol{K}_t$ 实现增益自适应调节。为了保证这些复杂模型逻辑能够顺利运行，本文设计了相应数据流处理逻辑。

第四章进行仿真分析。系统利用测试数据集评估目标检测精度与关联效果。内容对比不同算法下高阶跟踪精度（Higher Order Tracking Accuracy, HOTA）与身份识别分数（IDF1）等核心指标。此外实验数据证明混合模型对非线性机动具有较强自适应能力。相应地结果验证建立模型合理性。

第五章归纳全文研究工作。内容总结算法优势。此外文章梳理当前模型存在不足。相应地作者对未来研究新思路做出展望。

第二章　相关理论与技术基础

2.1　YOLOX 算法原理

视觉跟踪任务首先依赖于高性能的前端检测器的检测。本文使用 YOLOXv8 作为前端检测器，其作为 YOLO 系列的重要改进版本，通过引入解耦头（Decoupled Head）与无锚框（Anchor-free）机制，显著提升了复杂背景下目标的检测精度与推理速度。

2.1.1　解耦头设计

传统目标检测器的检测头通常将分类与定位任务耦合在同一特征层中进行预测，但这两种任务所关注的特征存在固有的冲突。YOLOX 通过解耦头结构将两路特征分离，分别预测类别概率和边界框坐标。这种结构不仅加快了模型的收敛速度，更在应对导弹这类在三维空间中姿态多变的精细目标时，展现出更高的检测敏感度与准确率。

2.1.2　无锚框与 SimOTA 策略

传统的基于锚框（Anchor-based）的算法需要预设大量的先验框，这在面对尺度变化剧烈的高机动目标时具有很大的局限性。YOLOX 采用无锚框机制，直接预测图像像素点到目标边界框边缘的偏移量，极大地减少了模型超参数的数量。同时，配合 SimOTA（Simplified Optimal Transport Assignment）动态标签分配策略，模型能够根据目标的实际重叠情况自适应地选择正样本，有效抑制了远距离小目标的漏检现象。

2.2　多目标跟踪框架

多目标跟踪旨在视频序列中为特定目标分配连续身份标志。现代跟踪系统普遍遵循先检测后跟踪（Tracking-by-Detection）范式。该范式将跟踪任务解耦为独立目标检测与数据关联两阶段。系统首先利用检测器提取单帧目标观测值。进而算法通过计算特征相似度或空间位置距离完成跨帧目标匹配。这种解耦设计极大提升系统灵活性。针对高机动目标跟踪任务本文采用 ByteTrack 算法作为基础关联框架。

2.2.1　ByteTrack 算法流程描述

ByteTrack 算法核心创新在于提出 BYTE 数据关联算法。该算法摒弃简单粗暴丢弃低置信度检测框的传统做法。完整工作流程首先根据预设阈值将当前帧所有

检测框划分为高置信度与低置信度两组。随后系统利用卡尔曼滤波对现有轨迹进行状态预测。通过计算预测结果与高置信度检测框之间相似度完成首次关联。相应地系统针对首次关联后剩余失配轨迹与低置信度检测框进行二次匹配。考虑到低分检测框常伴随严重遮挡或运动模糊导致外观特征不可靠。基于此二次匹配阶段仅使用 IoU 作为相似度度量。此举通过运动连续性恢复被遮挡目标。最终系统利用匹配成功检测框观测值更新轨迹状态。未匹配高置信度检测框被初始化为新轨迹。长时间未匹配轨迹则被剔除。

2.2.2 算法与卡尔曼滤波的关系

ByteTrack 算法跟踪逻辑高度依赖状态估计器预测能力。数据关联阶段前算法必须调用卡尔曼滤波预测步。系统利用上一时刻后验估计推算当前时刻轨迹先验位置。该预测结果在关联过程中发挥关键作用。首先卡尔曼滤波输出先验预测框确定搜索空间。算法据此计算预测位置与实际检测框之间 IoU 距离。此外当目标发生短暂遮挡导致检测器失效时卡尔曼滤波仍能依靠历史运动惯性给出轨迹预估位置。基于此匹配完成后算法将最优检测值作为观测输入回传至卡尔曼滤波更新步。系统进而实现轨迹状态向量实时修正。综上卡尔曼滤波为 ByteTrack 提供时序运动先验。相应地 ByteTrack 通过高效数据关联策略为滤波器持续递归提供准确量测更新。两者共同保障高机动导弹在复杂对抗环境下轨迹连续性。

2.3 经典状态估计理论

卡尔曼滤波（Kalman Filter, KF）是目标跟踪领域的核心状态估计算法，其在最小均方误差准则下，通过递归的“预测-更新”过程实现对系统状态的最优估计。

2.3.1 数学模型描述

设系统在 t 时刻的状态向量为 $\boldsymbol{x}_t$，量测向量（观测向量）为 $\boldsymbol{z}_t$。系统的离散线性状态空间模型定义如下：

$$\boldsymbol{x}_t = \boldsymbol{F}\boldsymbol{x}_{t-1} + \boldsymbol{w}_{t-1} \tag{2-1}$$

$$\boldsymbol{z}_t = \boldsymbol{H}\boldsymbol{x}_t + \boldsymbol{v}_t \tag{2-2}$$

式中，$\boldsymbol{F}$ 为状态转移矩阵；$\boldsymbol{H}$ 为量测矩阵；$\boldsymbol{w}_{t-1}$ 与 $\boldsymbol{v}_t$ 分别为系统过程噪声和量测噪声，通常假设二者均为零均值的高斯白噪声。

2.3.2 递归滤波过程

标准卡尔曼滤波的计算过程分为预测与更新两个独立阶段：

1. 预测阶段（时间更新）：

利用上一时刻的后验状态估计推算当前的先验状态估计与误差协方差：

$$\hat{\boldsymbol{x}}_{t|t-1} = \boldsymbol{F}\hat{\boldsymbol{x}}_{t-1|t-1} \tag{2-3}$$

$$\boldsymbol{P}_{t|t-1} = \boldsymbol{F}\boldsymbol{P}_{t-1|t-1}\boldsymbol{F}^T + \boldsymbol{Q} \tag{2-4}$$

式中，$\boldsymbol{P}$ 为估计误差协方差矩阵；$\boldsymbol{Q}$ 为过程噪声协方差矩阵。

2. 更新阶段（量测更新）：

结合当前的实际量测值对先验估计进行修正，以获得最优后验估计：

$$\boldsymbol{K}_t = \boldsymbol{P}_{t|t-1}\boldsymbol{H}^T(\boldsymbol{H}\boldsymbol{P}_{t|t-1}\boldsymbol{H}^T + \boldsymbol{R})^{-1} \tag{2-5}$$

$$\hat{\boldsymbol{x}}_{t|t} = \hat{\boldsymbol{x}}_{t|t-1} + \boldsymbol{K}_t(\boldsymbol{z}_t - \boldsymbol{H}\hat{\boldsymbol{x}}_{t|t-1}) \tag{2-6}$$

$$\boldsymbol{P}_{t|t} = (\boldsymbol{I} - \boldsymbol{K}_t\boldsymbol{H})\boldsymbol{P}_{t|t-1} \tag{2-7}$$

式中，$\boldsymbol{K}_t$ 为卡尔曼增益矩阵；$\boldsymbol{R}$ 为量测噪声协方差矩阵；$\boldsymbol{I}$ 为单位矩阵。

2.3.3　传统算法的局限性分析

标准卡尔曼滤波在处理高机动导弹目标时面临严峻挑战。首先，导弹的强机动性导致其运动规律具有显著的非线性特征，难以用线性方程精确描述。其次，作为一种模型驱动（Model-based）方法，其性能高度依赖于对系统状态空间模型的准确构建以及对过程噪声协方差 $\boldsymbol{Q}$ 与量测噪声协方差 $\boldsymbol{R}$ 的精确设定。

在复杂的实际战场环境下，噪声的统计特性往往未知且时变，标准卡尔曼滤波对模型及参数的失配极其敏感。一旦手工设定的 $\boldsymbol{Q}$、$\boldsymbol{R}$ 矩阵偏离实际物理过程，固定的滤波增益计算逻辑将无法自适应调整，从而导致跟踪精度发散或轨迹滞后。虽然传统滤波算法提供了稳健的递归架构，但其对参数设定精度的过度依赖限制了其在极端机动场景下的表现。本文后续引入的数据驱动的神经网络模型，在保留物理先验框架的基础上通过残差修正来降低系统对参数设定的敏感性。

第三章　融合神经网络与滤波的算法设计

3.1　混合模型总体架构设计

高机动导弹目标在复杂对抗环境中表现出强非线性与高动态特性。传统纯模型驱动状态估计算法高度依赖预设线性动力学模型。目标面对变轨机动时系统极易产生模型失配。基于此本文构建融合物理先验与数据驱动混合跟踪体系。

系统整体处理管线由目标检测与分级关联以及自适应状态估计三个核心模块构成。首先视频流图像帧输入至 YOLOX 前端检测器。系统提取目标边界框观测信息与检测置信度。随后 ByteTrack 框架利用二次匹配逻辑进行数据关联。关联过程核心环节引入 KalmanNet 替代标准线性卡尔曼滤波。KalmanNet 保留卡尔曼滤波中物理意义明确预测与更新一阶矩推算流程。相应地模型利用递归神经网络隐式接管误差协方差演化与卡尔曼增益计算。该架构在不破坏系统运动学先验前提下运行。此外系统赋予模型自适应处理非线性量测噪声与系统失配能力。

3.2　KalmanNet 状态估计网络设计

3.2.1　多维输入特征提取

为使神经网络有效评估并输出最优卡尔曼增益系统必须提取能够全面捕获状态估计过程及其不确定性输入特征。本文根据导弹运动状态与滤波反馈机制定义四类差分特征组合用以表征系统动态失配程度。系统利用相邻两帧间实际观测值瞬时变化定义观测残差（F_1）：

$$F_1 = \boldsymbol{z}_t - \boldsymbol{z}_{t-1} \tag{3-1}$$

此外系统计算当前时刻实际观测值与先验观测预测值之间偏差得到新息残差（F_2）。该指标是评估模型失配核心指标：

$$F_2 = \boldsymbol{z}_t - \boldsymbol{H}\hat{\boldsymbol{x}}_{t|t-1} \tag{3-2}$$

相应地反映相邻两帧间状态后验估计值演化规律特征被定义为状态演化差值（F_3）：

$$F_3 = \hat{\boldsymbol{x}}_{t|t} - \hat{\boldsymbol{x}}_{t-1|t-1} \tag{3-3}$$

最终同一时刻状态后验估计值相对于先验预测值修正量被定义为状态更新差值（F_4）：

$$F_4 = \hat{\boldsymbol{x}}_{t|t} - \hat{\boldsymbol{x}}_{t|t-1} \tag{3-4}$$

特征表达中 F_1 与 F_2 侧重于量测层面不确定性描述。此外 F_3 与 F_4 更多涵盖状态演化层面修正信息。高机动导弹在对抗环境下产生观测噪声与模型误差具有极高复杂性。基于此本文在实验阶段对不同特征组合进行严格验证。根据实验结果本文最终选取新息残差（F_2）与前向更新差值（F_4）作为 KalmanNet 二维输入特征。该组合保留关键物理失配信息。相应地网络能够更有效抑制由视觉检测引入高频观测噪声。此举最终引导网络输出更稳健卡尔曼增益修正量。

3.2.2 网络架构选择与设计

循环神经网络架构选型中本文共考虑三种不同模型方案。方案一与方案二侧重利用深度学习网络直接取代传统卡尔曼滤波。系统试图通过纯数据驱动方式学习目标运动规律。方案三则是本文最终采用架构。系统在保留卡尔曼滤波递归结构基础上利用神经网络对卡尔曼增益进行残差修正。前文图表已展示这三种架构具体结构拓扑及详细性能评估。

针对最终方案三本文设计了一种由三个独立门控循环单元（GRU）组成的解耦网络架构。标准卡尔曼滤波中增益计算依赖于过程噪声协方差 $\boldsymbol{Q}$ 与状态预测协方差 $\boldsymbol{P}_{t|t-1}$ 以及残差协方差 $\boldsymbol{S}$。相应地解耦架构专门设置三个独立 GRU 模块分别隐式跟踪这三个不确定性分量。

系统首先通过状态噪声 GRU 捕获高机动目标加速度突变等未建模动态。随后预测协方差 GRU 接收前置模块输出并负责记忆历史状态不确定性演化规律。最终残差协方差 GRU 综合特征映射输入与前两者隐状态评估当前量测可靠性。系统摒弃臃肿单分支叠加设计。该架构通过物理分治策略提升网络对各协方差矩阵动态拟合精度。为了保证这些复杂模型逻辑能够顺利运行解耦网络最终通过全连接层输出低维增益扰动向量。

3.2.3 基于网络输出的增益残差修正

具体实现中系统仍保留经典卡尔曼滤波状态转移与协方差传播机制。神经网络核心任务是输出增益修正项 $\Delta\boldsymbol{K}_t$。该修正项直接作用于由当前过程噪声 $\boldsymbol{Q}$ 与量测噪声 $\boldsymbol{R}$ 计算出经典增益 $\boldsymbol{K}_{t,\text{classical}}$ 之上。最终混合卡尔曼增益 $\boldsymbol{K}_t$ 表示为：

$$\boldsymbol{K}_t = \boldsymbol{K}_{t,\text{classical}} + \Delta\boldsymbol{K}_t \tag{3-5}$$

该方法降低系统对 $\boldsymbol{Q}$ 与 $\boldsymbol{R}$ 矩阵精确设定敏感性。相应地轻量化网络学会在经典增益邻域内进行有界调整。

3.3　模型训练策略与损失函数设计

实际应用中高动态非线性系统绝对最优卡尔曼增益真值难以获取。相应地 KalmanNet 无法进行直接监督学习。基于此本文采用基于最终状态估计误差端到端训练机制。

3.3.1　有监督损失函数

本文利用仿真平台或公开数据集提供目标真实轨迹作为网络训练监督信号。KalmanNet 输出最终作用于状态更新公式。相应地网络通过评估最终状态后验估计值 $\hat{\boldsymbol{x}}_{t|t}$ 与真实标签值 $\boldsymbol{x}_t^{GT}$ 之间偏差计算梯度。本文采用均方误差即 L2 范数平方作为时间步 t 损失函数：

$$\mathcal{L}_t = \left\|\hat{\boldsymbol{x}}_{t|t} - \boldsymbol{x}_t^{GT}\right\|_2^2 \tag{3-6}$$

整体序列损失为各时间步损失平均值。系统通过最小化该损失函数自动寻找增益计算策略。此举旨在使长期跟踪误差最小化。

3.3.2　由短及长的递进式训练策略

随时间反向传播优化过程中系统若直接使用长视频序列训练极易引发梯度消失或爆炸。该现象导致模型无法收敛。此外系统若仅使用极短轨迹训练会缺乏长期身份一致性记忆。此举导致身份识别分数指标表现不佳。

针对这一矛盾本文提出并验证由短及长两阶段联合微调策略。系统在初始迭代周期进入短序列稳定阶段。此时系统采用固定长度短轨迹片段进行截断反向传播训练。该阶段主要目标是快速稳定网络权重并使网络学会基础短期残差修正能力。随后系统进入长序列微调阶段。网络在初步收敛后引入整条长视频轨迹进行全长度梯度计算。该阶段强制网络学习长周期运动依赖关系。此外系统优化对局部遮挡与短暂丢失目标重识别能力。实验证明该联合训练策略有效抑制训练后期损失函数震荡。相应地系统显著提升高阶跟踪精度指标。

第四章　实验结果与分析

4.1　实验环境与数据集

本实验基于 Windows 平台通过 Python 语言实现，采用 Windows 11 操作系统，深度学习框架为 Pytorch 2.5.1，采用 CUDA 12.1 和 cuDNN 8.9 加速训练；所运行的硬件平台如下：处理器为 AMD Ryzen 7 5800H，显卡为 NVIDIA RTX 3060。

高机动导弹真实飞行视觉数据属于高度机密且极难获取。目前缺乏公开的、具有认可度的并且具有精确标注轨迹的导弹数据集。缺乏数据集难以训练深度神经网络。本文注意到多目标跟踪领域经典公开数据集 MOT17，该数据集包含大量复杂遮挡与目标交错的场景，这些场景能够检验跟踪算法基础状态估计与数据关联能力。基于此，本文首先在 MOT17 数据集上开展有效性验证实验，先通过该基准验证混合驱动架构的底层逻辑。

多目标跟踪算法的评价常使用官方测试集进行在线评估，该评估需要登录 Motchallenge 网站。由于本文目前无法获取该平台的在线评测权限，故采用当前普遍认可的离线拆分训练集的方法来获取系统性能数据。该方法是将官方训练集视频序列按时间帧对半划分，采用每个视频序列前半部分进行模型训练，并利用后半部分开展性能验证。本文将严格遵循 MOT17half 划分方式开展后续实验。

4.2　评价指标

为科学量化算法性能, 本文选取多目标跟踪领域国际通用指标进行评估, 评价标准如表 4.1 所列。

4.3　实验结果与分析

4.3.1　GRU 架构选择

在网络结构探索方面，本文考虑了两种计算卡尔曼增益的 RNN 架构：一种是隐藏状态容量较大的单层隐式跟踪架构；另一种是由三个门控循环单元（Gated Recurrent Unit, GRU）层组成的解耦跟踪架构，分别追踪状态噪声协方差矩阵、预测协方差矩阵及残差协方差矩阵。

基于这两种基础架构，本文设计了三种不同的 GRU 网络架构。架构 1 采用单层 GRU 完全替代传统卡尔曼滤波参数推算流程。架构 2 采用解耦设计并利用三层 GRU 分别追踪不同的协方差矩阵。架构 3 保留卡尔曼滤波基础数学框架并利用三

表 4.1 多目标跟踪指标含义

评价指标	定义
HOTA (↑)	综合衡量检测与关联精度
MOTA (↑)	综合衡量漏检误报与身份切换
IDF1 (↑)	评估全局轨迹身份一致性
DetA (↑)	衡量单帧目标定位精度
AssA (↑)	衡量跨帧身份匹配精度
Recall (↑)	真实目标检出比例
Precision (↑)	检测结果正确比例
IDP (↑)	预测轨迹分配正确身份比例
IDR (↑)	真实轨迹分配正确身份比例
IDSW (↓)	目标身份标识切换总次数
FP (↓)	背景误判为目标总次数
FN (↓)	真实目标漏检总次数
MT (↑)	连续跟踪时长超 80% 目标占比
PT	连续跟踪时长介于 20% 至 80% 目标占比
ML (↓)	连续跟踪时长低于 20% 目标占比

层 GRU 输出残差以修正卡尔曼增益。以上三种架构的结构分布如图 4.1所示

为客观对比不同架构的性能，本文在一致的实验条件下对三种网络分别开展 60 轮训练。所有实验均在相同软硬件环境运行，系统硬件采用 NVIDIA RTX 3060 显卡；软件框架均采用 PyTorch 2.5.1。固定随机种子为 42，以保证训练数据生成与验证集划分完全一致；统一采用 Adam 优化器并搭配余弦退火学习率衰减策略；此外，设置初始学习率为 1×10^{-3}，最小学习率为 1×10^{-5}。三种架构均采用相同时间步长与训练策略。

在训练策略方面，实验均采用了相同的短序列时间反向传播（Short BPTT）策略，时间步长（Sequence Length）固定为 20 帧。

性能对比结果如图图 4.2 所示。实验结果表明架构三在该条件下性能最优，其综合指标 HOTA 达到 68.18%，明显优于架构一的 64.00% 和架构二的 65.07%。

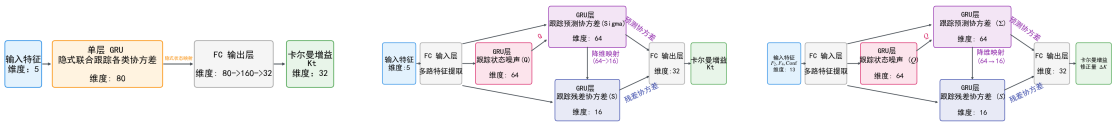

(a) 架构一框架图　　(b) 架构二框架图　　(c) 架构三框架图

图 4.1　不同网络架构框架图

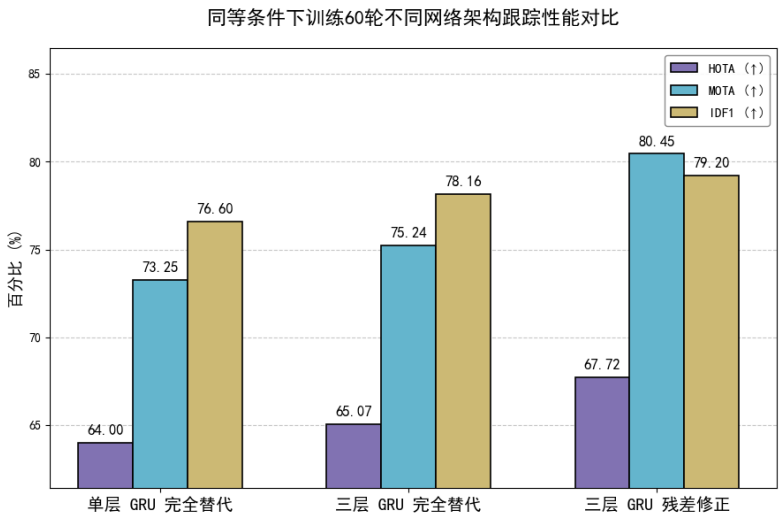

图 4.2　不同架构训练 60 轮性能对比图

4.3.2　训练策略分析

在深度学习中，训练序列长度会直接影响循环神经网络长程记忆保持能力，基于此本节将对比不同架构在使用不同长度训练序列时的性能变化。

等待修改常规方法通常采用短轨迹窗口更新网络参数，这有利于收敛，但在实际场景中面对高频遮挡时，记忆容量不足常常导致目标身份切换。基于此，我们引入了一种长短轨迹片段混合训练的方式，专门考察序列长度对纯数据驱动架构和物理启发架构的不同影响。

图 4.3 表明架构一与架构二在引入长片段进行训练后的指标变话，均出现显著的性能退化。这两种架构都保留了一定的运动学模型，包括但不限于物理先验和观测残差。但由于两种架构均使用神经网络负责输出完整的卡尔曼增益，当模型处理长片段、强遮挡的复杂轨迹时，短时的高强度噪声容易诱发神经网络输出极端增益值，导致系统误差发送累积，最终引发轨迹发散。

此外图 4.4 表明架构三在引入长片段训练后性有所上升。该架构仍保有卡尔曼滤波的数学框架，模型仅利用神经网络来修正卡尔曼增益。该机制保证了模型

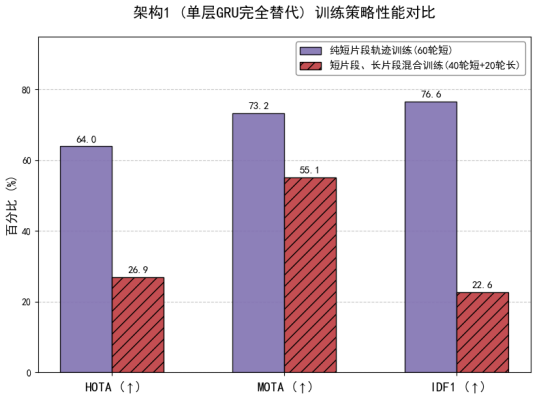

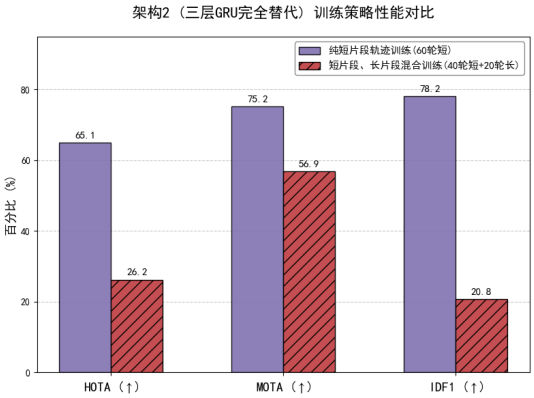

(b) 架构 1 在不同训练策略下模型的性能表现　　(a) 架构 2 在不同训练策略下模型的性能表现

图 4.3　两种架构在混合训练中的性能退化现象

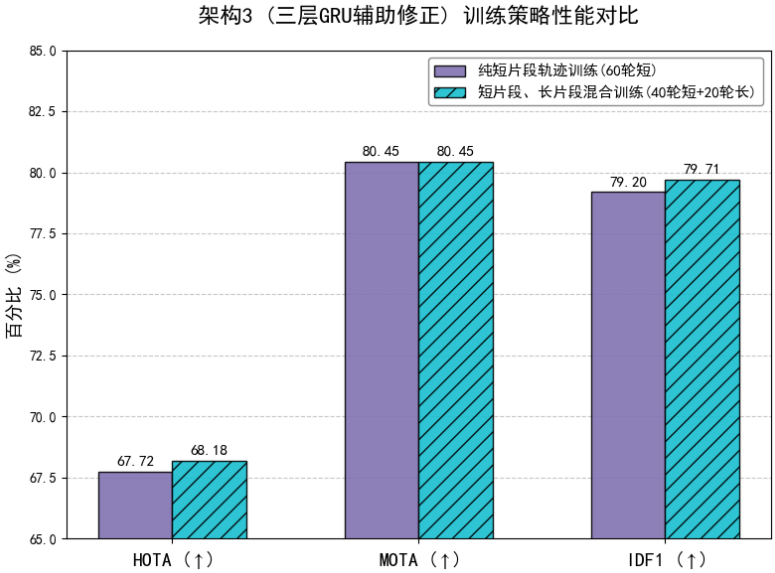

图 4.4　架构 3 在不同训练策略下模型的性能表现

在长片段、强遮挡的条件下依能维持稳定的轨迹预测。

如图 4.5(a) 所示，架构三在混合训练策略下的损失下降曲线更优。由于两种策略的短片段训练长度不同，导致余弦退火学习率衰减周期设置不同，从而使得短片段训练的前 40 轮损失下降低于长短片段混合训练的损失下降曲线。此外在相同的总训练轮次下，混合训练策略的损失收敛值更低。并且如图 4.5(b) 所示，架构三在混合训练策略中的模型跟踪性能指标 HOTA 更高。因此，本文确定采用架构三的混合训练策略。

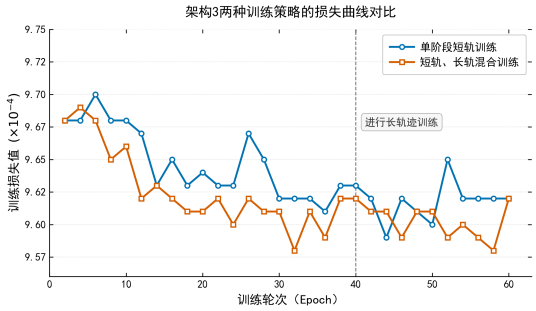

(a) 架构 3 不同训练曲线的损失曲线对比

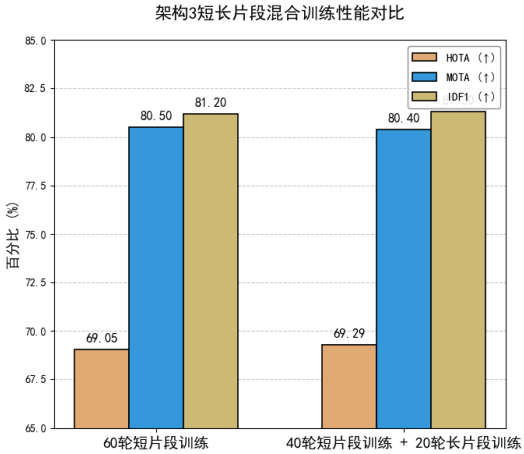

(b) 架构 3 长短片段混合训练性能对比

图 4.5　架构 3 长短片段混合训练策略评估

4.3.3　输入特征组合消融实验

输入特征选取直接决定神经网络感知系统动态失配程度的精准度，进而影响卡尔曼增益修正的准确性。有大量经验表明，具体的输入特征组合取决于具体的问题，并且有经验表明常用输入特征组合为F_1，F_2，F_4 和F_1，F_3，F_4。。因此本文设定了输入特征消融实验来确定模型的输入特征组合。

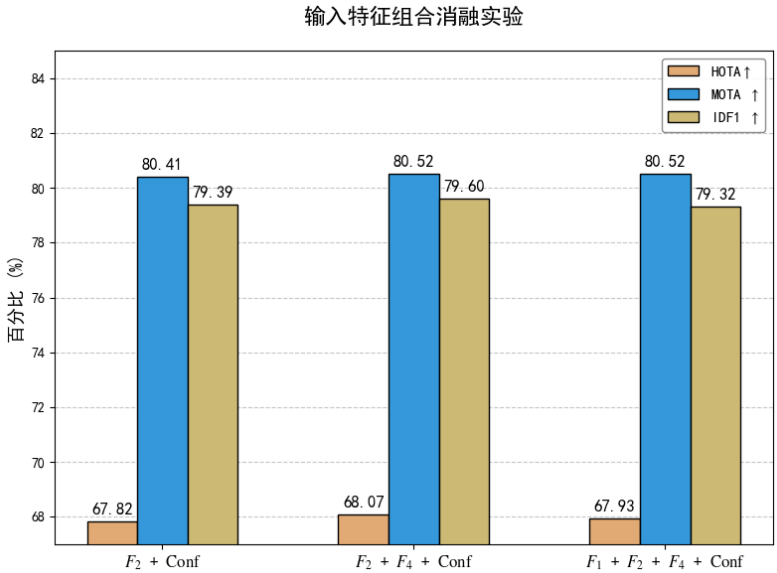

图 4.6　输入特征组合消融实验

如图 4.6 所示。实验数据表明新息残差 F_2 和状态更新差值 F_4 组合性能略微高于其他组合。该组合精准保留核心物理失配信息并有效抑制外部干扰。本文发现引入观测残差 F_1 反而造成各项评估指标全方位降低。

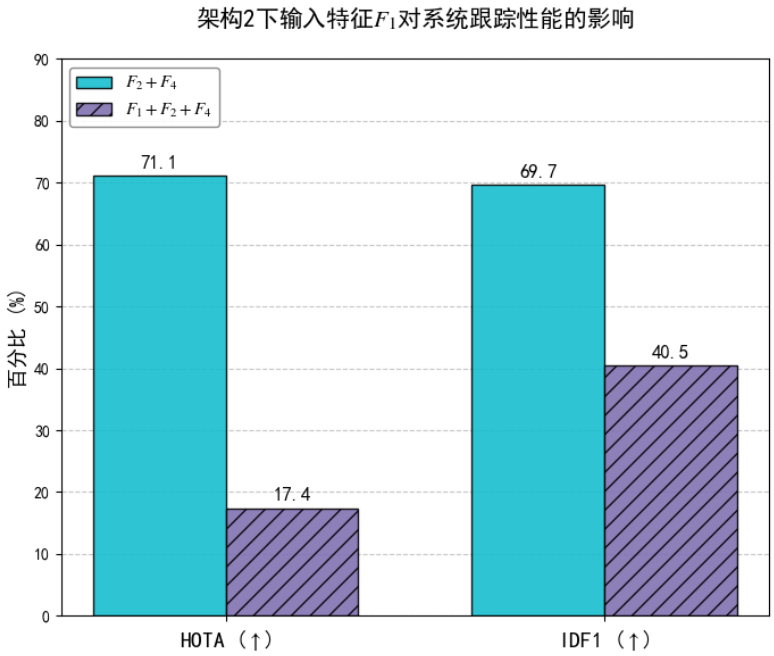

图 4.7 架构 2 下输入特征 F_1 对系统跟踪性能的影响

为深入探究该现象系统在敏感度更高架构 2 中单独测试 F_1 特征影响。图 4.7 清晰展示包含 F_1 后系统性能发生断崖式暴跌。分析认为观测残差 F_1 直接来源于相邻两帧前端检测框坐标差值。该特征包含大量视觉检测器引入高频随机噪声。严重噪声直接干扰网络内部隐状态更新过程。系统剔除 F_1 能够促使模型专注学习系统级物理状态偏差。相应地本文最终确立 F_2 与 F_4 组合作为标准输入特征。

4.3.4 模型对比与分析

4.4 YOLOX 检测器训练结果

高性能前端感知模块是跟踪任务稳定运行基础。检测器精度与误检率直接影响后续关联阶段数据质量。

图 4.8 展示 YOLOX 检测器在训练过程中整体精度变化。损失函数在迭代后期趋于稳定。系统说明模型已充分收敛。基于此检测器对导弹等特定机动目标展现出较高灵敏度。系统同时保持极低误检率。该感知模块为后续关联阶段提供可靠数据输入。

4.5 导弹数据集跟踪性能评估与效果展示

导弹机动场景下原版算法极易因运动非线性过强而丢失目标。本文利用 AirSim 仿真平台生成视频数据对改进算法进行验证。实验结果表明改进算法在导弹执行剧烈机动时能够通过自适应增益修正维持轨迹连续性。本文同时给出实际跟

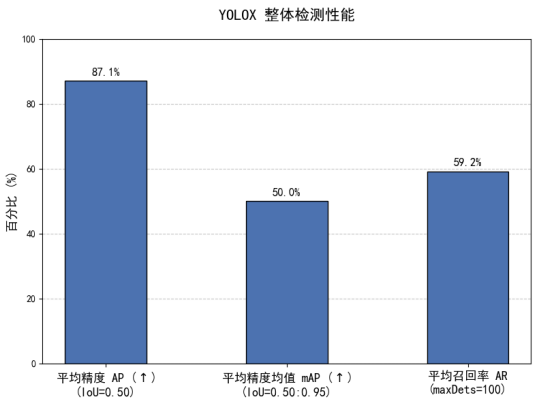

(a) yolox 整体精度

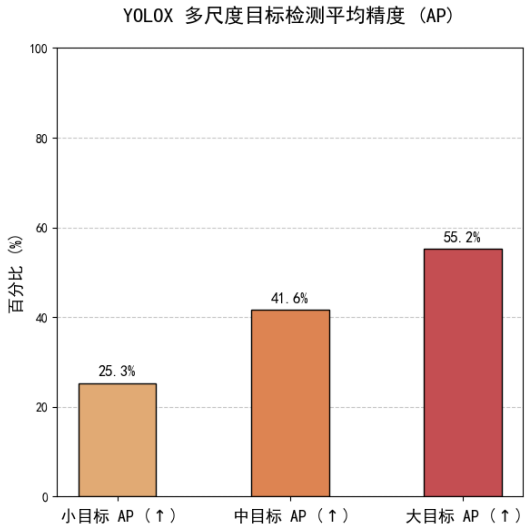

(b) yolox 各种目标识别精度

图 4.8　YOLOX 检测器训练评估结果

踪效果可视化展示。图像直观呈现系统在面对强非线性运动时预测框拟合能力。基于此本文工作有效缓解极端机动场景下状态估计精度不足难题。

致　谢

参考文献