班　级　220452

学　号　22049200392

西安电子科技大学

本科毕业设计论文

题　　目　融合神经网络和卡尔曼滤波的混合模型状态估计

学　　院　机电工程学院

专　　业　测控技术与仪器

学生姓名　王苏棋

导师姓名　董春云

摘　要

关键词：神经网络　　卡尔曼滤波　　状态估计

ABSTRACT

Keywords: Neural Networks Kalman Filter State Estimation

目 录

第一章 绪论 **1**
1.1 选题背景与研究意义 1
1.2 国内外研究现状 2
1.2.1 视觉目标检测与跟踪算法研究现状 2
1.2.2 状态估计与传统滤波算法的局限性 3
1.2.3 人工智能与滤波算法的深度融合 3
第二章 相关理论与技术基础 **5**
2.1 目标检测模型：YOLOX 算法原理 5
2.1.1 解耦头设计 5
2.1.2 无锚框与 SimOTA 策略 5
2.2 多目标跟踪框架：ByteTrack 关联策略 5
2.2.1 ByteTrack 算法流程描述 5
2.2.2 算法与卡尔曼滤波的关系 6
2.3 经典状态估计理论：标准卡尔曼滤波 6
2.3.1 数学模型描述 6
2.3.2 递归滤波过程 6
2.3.3 传统算法的局限性分析 7
第三章 融合神经网络与滤波的算法设计 **9**
3.1 混合模型总体架构设计 9
3.2 KalmanNet 状态估计网络设计 9
3.2.1 多维输入特征提取 9
3.2.2 网络架构选择与设计 10
3.2.3 基于网络输出的增益残差修正 10
3.3 模型训练策略与损失函数设计 10
3.3.1 有监督损失函数 11
3.3.2 由短及长的递进式训练策略 11
致谢 **13**
参考文献 **15**

第一章　绪论

1.1　选题背景与研究意义

随着现代军事技术的持续演进与战场对抗烈度的不断升级，高机动飞行器凭借其超高的突防速度、灵活的机动变轨能力以及精确的打击效果，在现代战争体系中占据了核心地位。此类目标能够执行远程精确打击与战术突防等多种关键任务，已成为影响战场态势的关键因素。随着推进技术与气动布局的不断演进，高机动导弹正朝着更高马赫数、更强隐身性能的方向发展，给国家空天防御体系及关键战略设施的保护机制带来了严谨的技术挑战。

面对此类具备极强毁伤能力和战略威慑力的目标，构建多层次、全方位的空天防御体系已成为各国战略防御的核心。在反导作战体系中，中段反导系统（Mid-course Defense System）占据着至关重要的地位。由于导弹的中段飞行阶段处于大气层外的真空环境，持续时间最长且飞行轨迹相对稳定，是实施拦截的最佳窗口期。现代中段反导体系通常采用天基预警探测、拦截弹精确打击的协同模式，利用部署在特定轨道上的预警卫星星座对弹道导弹进行全时段、全疆域的监控。卫星感知模块负责在导弹进入弹道中段后，对其进行持续的特征识别与轨迹跟踪，并根据计算结果通过高带宽数据链将目标状态向量实时传递给拦截火箭，引导动能拦截器完成最终的精确碰撞。

在天基拦截系统的感知模块设计中，计算机视觉与光学探测技术是实现目标识别的核心手段。在深空背景下，传统的雷达系统受限于卫星平台的载荷体积、功耗水平以及空间复杂的电磁干扰，难以实现高分辨率的特征提取。相比之下，搭载高分辨率光学传感器的天基视觉感知方案具备显著优势：在导弹进入弹道中段、发动机关机后，其红外特征会显著减弱，此时通过视觉传感器获取的目标光学图像信息，不仅能够实现对目标的精确三维空间定位，更在复杂诱饵干扰（如金属箔条、气球诱饵）中具备更强的真假弹头辨识能力。因此，以计算机视觉技术为基础的卫星识别系统，是天基中段反导网络获取目标观测数据的重要来源。

然而，获取高质量的视觉观测数据仅是拦截任务的前置条件，系统的观测效果取决于对目标高非线性动态轨迹的连续状态估计与预测能力。高机动导弹在突防过程中常采取不可预测的变轨机动，其运动模型具有极强的非线性；同时，天基

光学传感器在极远距离下提取的视觉量测特征（如目标检测框的坐标与尺度）不可避免地包含由成像极限和前端检测算法引入的复杂量测噪声。由于系统真实的动力学突变与视觉观测误差通常难以满足严格的线性高斯假设，传统卡尔曼滤波（Kalman Filter, KF）算法在处理此类时序数据时极易产生严重的模型失配，进而引发轨迹预测的发散与滞后。

近年来，随着深度神经网络（Deep Neural Network, DNN）技术的成熟，利用其强大的非线性拟合能力辅助状态估计成为新的突破口。构建融合神经网络与卡尔曼滤波的混合驱动架构，通过数据驱动方式隐式学习复杂的噪声分布特征，并根据视觉观测残差自适应调节滤波增益，能够有效补偿量测误差与机动模型失配。这一技术不仅是解决高机动目标中段连续跟踪难题的关键路径，更代表了未来高精度空天防御技术的重要发展方向。

1.2 国内外研究现状

1.2.1 视觉目标检测与跟踪算法研究现状

近年来，计算机视觉技术在目标检测与跟踪任务中取得了显著进展。在目标检测领域，YOLOX 算法是 YOLO（You Only Look Once）系列的重要演进版本，代表了单阶段检测方法的前沿水平。传统目标检测算法（如 YOLOv4、YOLOv5）普遍采用基于锚框（Anchor-based）的检测范式，需要预先设定大量敏感超参数，导致模型在面对尺度与形状各异的目标时泛化能力受限。为此，YOLOX 创新性地引入了无锚框（Anchor-free）机制，通过像素级回归策略直接预测目标边界框，在有效降低计算复杂度的同时提升了检测灵活性。此外，YOLOX 提出的” 解耦头”（Decoupled Head）结构从特征层面分离了分类与定位任务，缓解了二者之间的特征耦合冲突。配合 SimOTA 动态标签分配策略，YOLOX 在保证实时推理速度的同时，对复杂背景下高机动目标的检测展现出良好的鲁棒性。

尽管高性能检测器能够实现对单帧图像中目标的精确定位，但若要构建时间序列上的连续运动轨迹，则必须借助视觉多目标跟踪（Multiple Object Tracking, MOT）技术。现代 MOT 框架普遍遵循” 先检测后跟踪”（Tracking-by-Detection）的技术路径，其性能高度依赖于前端检测器的精度。早期的 SORT 算法利用卡尔曼滤波结合匈牙利算法实现了轻量级的目标关联，具有较高的运行效率；随后的 DeepSORT 在 SORT 的基础上引入了深度外观特征（ReID）模块，增强了遮挡场景下的身份维持能力，但在拥挤场景中易受干扰且计算开销相对较大。在此背景下，

ByteTrack 算法提出了一种基于检测置信度的分级关联策略，通过保留并二次利用低分检测框来恢复被错误过滤的目标信息，有效克服了目标在快速运动或相互遮挡时因置信度下降而导致轨迹断裂的问题，显著提升了跟踪的连续性与整体鲁棒性，成为当前该领域重要的基准算法之一。

1.2.2　状态估计与传统滤波算法的局限性

在涉及导弹等高速机动对象的复杂应用场景中，实现精确且平滑的连续轨迹预测需要对状态估计理论有深入的掌握。卡尔曼滤波是处理线性高斯系统状态估计问题的最优估计器，其采用”预测-更新”的递归闭环机制，通过卡尔曼增益对预测值与量测值进行加权融合，从而得到最优后验状态估计。然而，标准卡尔曼滤波要求系统满足线性叠加原理，且过程噪声与量测噪声均需服从高斯分布。

针对物理系统中普遍存在的非线性特征，学术界发展出了扩展卡尔曼滤波（Extended Kalman Filter，EKF）和无迹卡尔曼滤波（Unscented Kalman Filter，UKF）等改进方法。然而，上述变体本质上仍属于模型驱动方法，高度依赖精确的系统动力学方程以及先验已知的过程噪声协方差矩阵 $\mathbf{Q}$ 和量测噪声协方差矩阵 $\mathbf{R}$。当目标进行未知的强机动飞行时，模型参数与实际动态之间产生失配，固定参数的滤波器难以及时响应动态变化，极易导致估计精度下降甚至发散。

1.2.3　人工智能与滤波算法的深度融合

针对传统模型驱动方法的上述局限性，”人工智能与滤波相结合”的技术路线逐渐成为研究热点。长短期记忆网络（Long Short-Term Memory，LSTM）通过精心设计的门控机制有效解决了长序列训练中的梯度消失问题，具备强大的时序特征提取与历史信息记忆能力，常被用于对复杂非线性运动残差进行建模，以补偿传统滤波器的系统误差。

作为”人工智能赋能滤波”领域的代表性工作，KalmanNet 提出了一种深度融合的混合驱动架构。该方法保留了卡尔曼滤波中物理意义明确的状态更新结构，同时以递归神经网络（Recurrent Neural Network，RNN）替代了传统算法中基于固定协方差矩阵计算卡尔曼增益的过程。KalmanNet 通过数据驱动的方式，根据输入的观测残差序列实时感知系统模型的失配程度，进而动态输出最优增益矩阵。该方法有效摆脱了对精确噪声统计特性的强依赖，赋予了滤波器较强的非线性适应能力与自适应性。顺应这一研究趋势，在 ByteTrack 框架中集成自适应卡尔曼滤波模块，并针对导弹目标的高机动特性进行专项优化，有望在复杂对抗环境下实现更

精准、更鲁棒的目标状态估计，具有重要的研究价值与工程意义。

第二章　相关理论与技术基础

2.1　YOLOX 算法原理

高机动目标的视觉跟踪任务首先依赖于高性能的前端检测器。本文采用 YOLOX 算法作为基础感知模型，其作为 YOLO 系列的重要改进版本，通过引入解耦头（Decoupled Head）与无锚框（Anchor-free）机制，显著提升了复杂背景下目标的检测精度与推理速度。

2.1.1　解耦头设计

传统目标检测器的检测头通常将分类与定位任务耦合在同一特征层中进行预测，但这两种任务所关注的特征存在固有的冲突。YOLOX 通过解耦头结构将两路特征分离，分别预测类别概率和边界框坐标。这种结构不仅加快了模型的收敛速度，更在应对导弹这类在三维空间中姿态多变的精细目标时，展现出更高的检测敏感度与准确率。

2.1.2　无锚框与 SimOTA 策略

传统的基于锚框（Anchor-based）的算法需要预设大量的先验框，这在面对尺度变化剧烈的高机动目标时具有很大的局限性。YOLOX 采用无锚框机制，直接预测图像像素点到目标边界框边缘的偏移量，极大地减少了模型超参数的数量。同时，配合 SimOTA（Simplified Optimal Transport Assignment）动态标签分配策略，模型能够根据目标的实际重叠情况自适应地选择正样本，有效抑制了远距离小目标的漏检现象。

2.2　多目标跟踪框架

多目标跟踪旨在视频序列中为特定目标分配连续身份标志。现代跟踪系统普遍遵循先检测后跟踪（Tracking-by-Detection）范式。该范式将跟踪任务解耦为独立目标检测与数据关联两阶段。系统首先利用检测器提取单帧目标观测值。进而算法通过计算特征相似度或空间位置距离完成跨帧目标匹配。这种解耦设计极大提升系统灵活性。针对高机动目标跟踪任务本文采用 ByteTrack 算法作为基础关联框架。

2.2.1　ByteTrack 算法流程描述

ByteTrack 算法核心创新在于提出 BYTE 数据关联算法。该算法摒弃简单粗暴丢弃低置信度检测框的传统做法。完整工作流程首先根据预设阈值将当前帧所有

检测框划分为高置信度与低置信度两组。随后系统利用卡尔曼滤波对现有轨迹进行状态预测。通过计算预测结果与高置信度检测框之间相似度完成首次关联。相应地系统针对首次关联后剩余失配轨迹与低置信度检测框进行二次匹配。考虑到低分检测框常伴随严重遮挡或运动模糊导致外观特征不可靠。基于此二次匹配阶段仅使用 IoU 作为相似度度量。此举通过运动连续性恢复被遮挡目标。最终系统利用匹配成功检测框观测值更新轨迹状态。未匹配高置信度检测框被初始化为新轨迹。长时间未匹配轨迹则被剔除。

2.2.2 算法与卡尔曼滤波的关系

ByteTrack 算法跟踪逻辑高度依赖状态估计器预测能力。数据关联阶段前算法必须调用卡尔曼滤波预测步。系统利用上一时刻后验估计推算当前时刻轨迹先验位置。该预测结果在关联过程中发挥关键作用。首先卡尔曼滤波输出先验预测框确定搜索空间。算法据此计算预测位置与实际检测框之间 IoU 距离。此外当目标发生短暂遮挡导致检测器失效时卡尔曼滤波仍能依靠历史运动惯性给出轨迹预估位置。基于此匹配完成后算法将最优检测值作为观测输入回传至卡尔曼滤波更新步。系统进而实现轨迹状态向量实时修正。综上卡尔曼滤波为 ByteTrack 提供时序运动先验。相应地 ByteTrack 通过高效数据关联策略为滤波器持续递归提供准确量测更新。两者共同保障高机动导弹在复杂对抗环境下轨迹连续性。

2.3 经典状态估计理论

卡尔曼滤波（Kalman Filter, KF）是目标跟踪领域的核心状态估计算法，其在最小均方误差准则下，通过递归的“预测-更新”过程实现对系统状态的最优估计。

2.3.1 数学模型描述

设系统在 t 时刻的状态向量为 $\boldsymbol{x}_t$，量测向量（观测向量）为 $\boldsymbol{z}_t$。系统的离散线性状态空间模型定义如下：

$$\boldsymbol{x}_t = \boldsymbol{F}\boldsymbol{x}_{t-1} + \boldsymbol{w}_{t-1} \tag{2-1}$$

$$\boldsymbol{z}_t = \boldsymbol{H}\boldsymbol{x}_t + \boldsymbol{v}_t \tag{2-2}$$

式中，$\boldsymbol{F}$ 为状态转移矩阵；$\boldsymbol{H}$ 为量测矩阵；$\boldsymbol{w}_{t-1}$ 与 $\boldsymbol{v}_t$ 分别为系统过程噪声和量测噪声，通常假设二者均为零均值的高斯白噪声。

2.3.2 递归滤波过程

标准卡尔曼滤波的计算过程分为预测与更新两个独立阶段：

1. 预测阶段（时间更新）：

利用上一时刻的后验状态估计推算当前的先验状态估计与误差协方差：

$$\hat{\boldsymbol{x}}_{t|t-1} = \boldsymbol{F}\hat{\boldsymbol{x}}_{t-1|t-1} \tag{2-3}$$

$$\boldsymbol{P}_{t|t-1} = \boldsymbol{F}\boldsymbol{P}_{t-1|t-1}\boldsymbol{F}^T + \boldsymbol{Q} \tag{2-4}$$

式中，$\boldsymbol{P}$ 为估计误差协方差矩阵；$\boldsymbol{Q}$ 为过程噪声协方差矩阵。

2. 更新阶段（量测更新）：

结合当前的实际量测值对先验估计进行修正，以获得最优后验估计：

$$\boldsymbol{K}_t = \boldsymbol{P}_{t|t-1}\boldsymbol{H}^T(\boldsymbol{H}\boldsymbol{P}_{t|t-1}\boldsymbol{H}^T + \boldsymbol{R})^{-1} \tag{2-5}$$

$$\hat{\boldsymbol{x}}_{t|t} = \hat{\boldsymbol{x}}_{t|t-1} + \boldsymbol{K}_t(\boldsymbol{z}_t - \boldsymbol{H}\hat{\boldsymbol{x}}_{t|t-1}) \tag{2-6}$$

$$\boldsymbol{P}_{t|t} = (\boldsymbol{I} - \boldsymbol{K}_t\boldsymbol{H})\boldsymbol{P}_{t|t-1} \tag{2-7}$$

式中，$\boldsymbol{K}_t$ 为卡尔曼增益矩阵；$\boldsymbol{R}$ 为量测噪声协方差矩阵；$\boldsymbol{I}$ 为单位矩阵。

2.3.3　传统算法的局限性分析

标准卡尔曼滤波在处理高机动导弹目标时面临严峻挑战。首先，导弹的强机动性导致其运动规律具有显著的非线性特征，难以用线性方程精确描述。其次，作为一种模型驱动（Model-based）方法，其性能高度依赖于对系统状态空间模型的准确构建以及对过程噪声协方差 $\boldsymbol{Q}$ 与量测噪声协方差 $\boldsymbol{R}$ 的精确设定。

在复杂的实际战场环境下，噪声的统计特性往往未知且时变，标准卡尔曼滤波对模型及参数的失配极其敏感。一旦手工设定的 $\boldsymbol{Q}$、$\boldsymbol{R}$ 矩阵偏离实际物理过程，固定的滤波增益计算逻辑将无法自适应调整，从而导致跟踪精度发散或轨迹滞后。虽然传统滤波算法提供了稳健的递归架构，但其对参数设定精度的过度依赖限制了其在极端机动场景下的表现。本文后续引入的数据驱动的神经网络模型，在保留物理先验框架的基础上通过残差修正来降低系统对参数设定的敏感性。

第三章　融合神经网络与滤波的算法设计

3.1　混合模型总体架构设计

针对高机动导弹目标在复杂对抗环境中表现出的强非线性与高动态特性，传统纯模型驱动（Model-driven）的状态估计算法因高度依赖预设的线性动力学模型，在面对变轨机动时极易产生模型失配。为此，本文构建了一种融合物理先验与数据驱动（Data-driven）的混合跟踪体系。

系统的整体处理管线由目标检测、分级关联与自适应状态估计三个核心模块构成。首先，视频流图像帧输入至 YOLOX 前端检测器，提取出目标的边界框观测信息与检测置信度；随后，在 ByteTrack 框架的二次匹配逻辑下进行数据关联。在关联过程的最核心环节，本文引入 KalmanNet 替代了标准的线性卡尔曼滤波。KalmanNet 保留了卡尔曼滤波中物理意义明确的“预测-更新”一阶矩推算流程，但利用递归神经网络（RNN）隐式接管了误差协方差的演化与卡尔曼增益的计算。该架构在不破坏系统运动学先验的前提下，赋予了模型自适应处理非线性量测噪声与系统失配的能力。

3.2　KalmanNet 状态估计网络设计

3.2.1　多维输入特征提取

为使神经网络能够有效评估并输出最优卡尔曼增益，必须提取能够全面捕获状态估计过程及其不确定性的输入特征。根据导弹运动状态与滤波反馈机制，本文定义了如下四类差分特征组合用于表征系统的动态失配程度：

1. **观测残差**（F_1）：反映了相邻两帧间实际观测值的瞬时变化，定义为：

$$F_1 = \boldsymbol{z}_t - \boldsymbol{z}_{t-1} \tag{3-1}$$

2. **新息残差**（F_2）：反映了当前时刻实际观测值与先验观测预测值之间的偏差，是评估模型失配的核心指标：

$$F_2 = \boldsymbol{z}_t - \boldsymbol{H}\hat{\boldsymbol{x}}_{t|t-1} \tag{3-2}$$

3. **状态演化差值**（F_3）：反映了相邻两帧间状态后验估计值的演化规律：

$$F_3 = \hat{\boldsymbol{x}}_{t|t} - \hat{\boldsymbol{x}}_{t-1|t-1} \tag{3-3}$$

4. **状态更新差值（F_4）**：反映了同一时刻状态后验估计值相对于先验预测值的修正量：

$$F_4 = \hat{\boldsymbol{x}}_{t|t} - \hat{\boldsymbol{x}}_{t|t-1} \tag{3-4}$$

在特征表达中，F_1 与 F_2 侧重于量测层面的不确定性描述，而 F_3 与 F_4 则更多涵盖了状态演化层面的修正信息。考虑到高机动导弹在对抗环境下产生的观测噪声与模型误差具有极高的复杂性，本文在实验阶段对不同特征组合进行了验证。根据实验结果，本文最终选取了新息残差（F_2）与前向更新差值（F_4）作为 KalmanNet 的二维输入特征。该组合在保留关键物理失配信息的同时，能够更有效地抑制由视觉检测引入的高频观测噪声，从而引导网络输出更稳健的卡尔曼增益修正量。

3.2.2 网络架构选择与设计

在循环神经网络（RNN）的架构选型中，本文共考虑了三种不同的模型方案：方案一与方案二侧重于利用深度学习网络直接取代传统的卡尔曼滤波，试图通过纯数据驱动的方式学习目标运动规律；方案三则是本文最终采用的架构，即在保留卡尔曼滤波递归结构的基础上，利用神经网络对卡尔曼增益进行残差修正。关于这三种架构的具体结构拓扑及详细性能评估，如图所示。

针对本文最终采用的方案三，本文采用了一种由三个 GRU 层并行组成的解耦网络架构。在标准卡尔曼滤波中，增益的计算依赖于过程噪声协方差 $\boldsymbol{Q}$、状态预测协方差 $\boldsymbol{P}_{t|t-1}$ 以及残差协方差 $\boldsymbol{S}$。解耦架构专门设置了三个独立的 GRU 模块分别隐式跟踪这三个不确定性分量：1. 状态噪声 GRU 负责捕获高机动目标的加速度突变等未建模动态。2. 预测协方差 GRU 负责记忆并演化历史状态的不确定性。3. 残差协方差 GRU 则综合量测特征与前两者的隐状态，评估当前量测的可靠性。

3.2.3 基于网络输出的增益残差修正

在具体实现中，系统仍保留了经典卡尔曼滤波中的状态转移与协方差传播机制。神经网络的任务是输出一个增益修正项 $\Delta\boldsymbol{K}_t$，并作用于由当前 $\boldsymbol{QR}$ 计算出的经典增益 $\boldsymbol{K}_{t,\text{classical}}$。最终的混合卡尔曼增益 $\boldsymbol{K}_t$ 表示为：

$$\boldsymbol{K}_t = \boldsymbol{K}_{t,\text{classical}} + \Delta\boldsymbol{K}_t \tag{3-5}$$

3.3 模型训练策略与损失函数设计

在实际应用中，由于高动态非线性系统下“绝对最优的卡尔曼增益”真值无法获取，KalmanNet 无法进行直接的监督学习。因此，本文采用基于最终状态估计误差的端到端（End-to-End）训练机制。

3.3.1　有监督损失函数

本文利用仿真平台或公开数据集中提供的目标真实轨迹（Ground Truth），将其作为网络的训练监督信号。由于 KalmanNet 的输出最终作用于状态更新公式，网络可以通过评估最终的状态后验估计值 $\hat{\boldsymbol{x}}_{t|t}$ 与真实标签值 $\boldsymbol{x}_t^{GT}$ 之间的偏差来计算梯度。本文采用均方误差（MSE）即 L2 范数的平方作为时间步 t 的损失函数：

$$\mathcal{L}_t = \left\| \hat{\boldsymbol{x}}_{t|t} - \boldsymbol{x}_t^{GT} \right\|_2^2 \tag{3-6}$$

整体序列损失则为各时间步损失的平均值。通过最小化该损失函数，网络能够自动寻找一种使长期跟踪误差最小化的增益计算策略。

3.3.2　由短及长的递进式训练策略

在随时间反向传播（BPTT）的优化过程中，若直接使用数百帧的长视频序列进行训练，极易引发 RNN 梯度的消失或爆炸，导致模型无法收敛。而若仅使用极短轨迹训练，模型又会缺乏长期的身份一致性记忆，导致 IDF1（身份识别分数）指标不佳。

针对这一矛盾，本文提出并验证了“由短及长”的两阶段联合微调策略：1. **短序列稳定阶段**：在训练前 40 个 Epoch 中，采用固定长度为 20 帧的短轨迹片段进行截断 BPTT 训练。这一阶段的主要目标是快速稳定网络权重，使网络学会基本的短期残差修正能力。2. **长序列微调阶段**：在网络初步收敛后的 20 个 Epoch 中，引入整条长视频轨迹进行全长度 BPTT 计算。这一阶段强制网络学习长周期的运动依赖关系，优化对局部遮挡和短暂丢失目标的重识别与重关联能力。

实验证明，该联合训练策略在抑制训练后期损失函数（Loss）震荡的同时，显著提升了系统的高阶跟踪精度（Higher Order Tracking Accuracy, HOTA）。

致　谢

参考文献