班　级　220452

学　号　22049200392

西安电子科技大学

本科毕业设计论文

题　　目　融合神经网络和卡尔曼滤波的混合模型状态估计

学　　院　机电工程学院

专　　业　测控技术与仪器

学生姓名　王苏棋

导师姓名　董春云

摘　要

关键词：神经网络　　卡尔曼滤波　　状态估计

ABSTRACT

Keywords: Neural Networks Kalman Filter State Estimation

目 录

第一章 绪论 1
1.1 选题背景与研究意义 1
1.2 国内外研究现状 2
1.2.1 视觉目标检测算法 2
1.2.2 多目标跟踪算法 2
1.2.3 状态估计与传统滤波算法 4
1.2.4 人工智能与滤波算法的融合 4
1.3 论文研究工作及安排 5
第二章 相关理论与技术基础 7
2.1 YOLOX 算法原理 7
2.1.1 解耦头设计 7
2.1.2 无锚框与 SimOTA 策略 7
2.2 ByteTrack 算法流程 7
2.2.1 ByteTrack 算法流程描述 7
2.2.2 算法与卡尔曼滤波的关系 8
2.3 经典状态估计理论 9
2.3.1 数学模型描述 9
2.3.2 递归滤波过程 9
2.3.3 传统算法的局限性分析 10
第三章 融合神经网络与滤波的算法设计 11
3.1 系统总体架构设计 11
3.2 KalmanNet 状态估计网络设计 11
3.2.1 多维输入特征提取 11
3.2.2 网络架构选择与设计 12
3.2.3 网络输出 12
3.3 损失函数设计与模型训练策略 13
3.3.1 损失函数 13
3.3.2 训练策略 14

第四章 实验结果与分析 15
4.1 实验环境与数据集 15
4.2 评价指标 15
4.3 实验结果与分析 15
4.3.1 GRU 架构选择 15
4.3.2 训练策略分析 17
4.3.3 输入特征组合消融实验 19
4.3.4 模型对比与分析 20
4.4 YOLOX 检测器训练结果 22
4.5 导弹数据集跟踪性能评估与效果展示 22
致谢 25
参考文献 27

第一章　绪论

1.1　选题背景与研究意义

现代军事技术持续演进，战场对抗强度不断升级。在此背景下，高机动飞行器凭借突出的突防速度与打击精度，在现代战争中扮演着日益重要的角色。此类目标能够执行远程精确打击与战术突防等多种任务，对战场态势产生重要影响。随着推进技术与气动布局的持续发展，高机动导弹正朝着更高马赫数、更强隐身性能方向演进，给空天防御体系及关键设施防护带来了显著的技术挑战[1]

在实际战场环境中，导弹可能以多批次、多方向的形式协同突防，多目标同时出现在观测视场内的情况并不少见。能否对多个高机动导弹实施连续、稳定的跟踪，是防御系统进行态势感知与威胁评估时需要面对的问题之一[1]。光学传感器具备被动无源、不易受电磁干扰的特点，可作为导弹多目标跟踪的一种感知手段。然而，导弹在高速飞行中空间尺度变化迅速、姿态调整频繁，加之弹道具有明显的非线性特征，使得其视觉表观特征呈现高度不稳定性。同时，多目标之间可能发生的相互遮挡、形貌高度相似以及密集编队带来的数据关联模糊，进一步增加了跟踪的难度。

在远距离光学观测条件下，成像系统受物理分辨极限与前端检测算法误差的影响，量测数据中通常会混入复杂的高频噪声[1]。

针对上述问题，近年来深度神经网络（Deep Neural Network, DNN）为复杂非线性状态估计提供了新的解决思路。其核心思想是在保留卡尔曼滤波（Kalman Filter, KF）状态更新结构的基础上，利用 DNN 替代固定的协方差增益计算环节。该类混合驱动架构使网络能够从历史观测残差序列中学习系统动力学的偏差特征，并输出自适应的卡尔曼增益，从而对量测误差与模型失配进行动态补偿。

KalmanNet 是该方向下极具代表性的工作。它利用递归神经网络（Recurrent Neural Network, RNN）实时计算动态增益矩阵，使系统即使在未知空间噪声统计特性的条件下，依然能够维持极高的状态估计精度[2]。与此同时，在视觉多目标跟踪领域，ByteTrack 等算法仍采用标准 KF 作为运动预测的核心模块[3]，但其固定的参数配置难以适应高机动目标状态的突发跳变。

为此，本文提出将 KalmanNet 所代表的自适应卡尔曼滤波模块深度集成至

ByteTrack 算法框架内部，提高跟踪算法的跟踪性能。

1.2 国内外研究现状

1.2.1 视觉目标检测算法

计算机视觉检测技术持续演进。单阶段检测方法中 YOLOX 算法作为 YOLO 系列重要演进版本展现出卓越性能。传统检测范式如 YOLOv4 与 YOLOv5 主要采用基于锚框机制。此类方法需要预先设定大量敏感超参数。相应地模型面对尺度与形状各异目标时泛化能力受到限制。

基于此 YOLOX 算法引入无锚框机制。系统通过像素级回归策略直接预测目标边界框。此举显著降低计算复杂度并提升检测灵活性。此外 YOLOX 采用解耦头结构。该结构从特征层面分离分类与定位任务。相应地解耦操作有效缓解两类任务特征耦合冲突。系统配合 SimOTA 动态标签分配策略在保证实时推理速度前提下实现复杂背景下高机动目标鲁棒检测。为了提升这些检测器在实际战场环境下可靠性，研究人员不断优化损失函数与正负样本采样逻辑。

本文最终选用 YOLOXv8 算法作为视觉感知底层模块。该架构深度继承前述 YOLOX 无锚框范式与解耦头核心优势。此外该版本引入全新跨阶段局部网络特征提取模块。该底层结构优化提供更丰富且高效梯度流信息。系统同步采用任务对齐样本分配机制替代早期策略。该匹配机制直接提升密集重叠目标分类与定位一致性。基于此 YOLOXv8 架构在复杂空间背景下具备最优实时推理速度与检测精度。该先进前端完全满足高机动多目标连续跟踪严苛量测需求。

1.2.2 多目标跟踪算法

高性能检测器能够从单帧图像中获取目标的空间位置。然而，要恢复目标在连续时间序列上的运动轨迹，必须依赖多目标跟踪技术。该技术的核心任务是将不同帧中属于同一目标的检测结果进行关联，并为其分配唯一且稳定的身份标签。

近年来，多目标跟踪算法可根据检测与特征提取的耦合程度，可以划分为三类范式。

第一类是分离检测与特征提取的范式（Separate Detection and Embedding, SDE）。该范式将目标检测与特征提取分为两个独立阶段。检测器先输出目标边界框，再由独立模块提取外观特征用于帧间关联。SDE 范式又可细分为离线方法和在线方法。离线方法利用整段视频的未来信息进行全局优化，但计算代价高，不具备实时性。在线方法仅利用当前帧及过去帧的信息进行实时关联决策。典型算法如 SORT，它

采用卡尔曼滤波与匈牙利算法实现高速匹配。DeepSORT 在此基础上引入深度外观特征模块，增强了遮挡场景下的身份保持能力。ByteTrack 则提出基于检测置信度的分级关联策略，通过保留并二次利用低分检测框，有效解决了目标因遮挡或快速运动导致轨迹断裂的问题。

第二类是联合检测与特征提取的范式（Joint Detection and Embedding, JDE）。该范式在单个网络中同时完成目标检测和 ReID 特征提取。相比 SDE，JDE 通过共享骨干网络减少了计算开销。代表算法包括 JDE 和 FairMOT。FairMOT 进一步指出锚框机制与 ReID 特征学习存在本质冲突，转而采用无锚框检测头，在精度与速度间取得了较好平衡。然而，JDE 范式仅将检测与特征提取两部分联合，模型复杂度依然较高。此外，检测损失与 ReID 损失之间缺乏有效的梯度回传通路，导致难以进行全局优化。

第三类是联合检测与跟踪的范式（Joint Detection and Tracking, JDT）。该范式在单个网络中同时完成目标检测、特征提取与帧间关联三个子任务。它以相邻多帧图像为输入，基于目标先前的运动或外观信息预测其当前位置偏移量或外观特征，从而直接完成目标关联。当前基于 JDT 范式的算法主要分为两类。一类是基于孪生网络的方法，利用共享权重的双分支结构进行目标匹配。另一类是基于 Transformer 的方法，如 MOTR，它将目标检测与跟踪查询向量统一建模，以端到端方式直接输出带身份标签的轨迹。

在上述三类范式中，本文选择基于 SDE 范式开展工作。由于 SDE 范式的模块解耦最为清晰，检测器与关联模块可分别独立优化。这便于本文改进跟踪算法的数据关联环节，以适配高机动目标的运动特性。因此，本文选择 SDE 框架。

在 SDE 框架下的诸多算法中，ByteTrack 具有以下若干优势。首先，ByteTrack 提出了一种基于检测置信度的分级关联策略，即 BYTE 策略。该策略的核心思想在于，不简单依赖单一置信度阈值过滤检测框，而是将高置信度检测框与低置信度检测框分别处理、逐级关联。这一设计有效克服了传统方法中因目标遮挡或快速机动导致检测置信度骤降，进而引发轨迹断裂的问题。其次，BYTE 策略对低分检测框的保留与二次利用，使得算法在无需引入额外计算开销的前提下，显著提升了跟踪轨迹的连续性与完整性。并且，ByteTrack 算法与 DeepSORT 等依赖独立外观特征模块的方法不同，其不过度依赖 ReID 特征，这使得其计算效率更高。

综上所述，ByteTrack 以其简洁的底层框架以及对遮挡与机动场景的鲁棒性，

契合了本文目标。因此，本文选择在 SDE 范式下，以 ByteTrack 算法为基础框架，对其状态估计模块展开后续改进工作。

1.2.3 状态估计与传统滤波算法

状态估计理论是构成连续轨迹预测的底层数学基础。早期卡尔曼滤波确立了线性高斯系统下的最优估计框架。该算法采用预测与更新两步递归计算机制，通过卡尔曼增益对先验状态预测值与当前量测值进行加权融合，最终输出系统的最优后验状态序列。然而，标准卡尔曼滤波的适用条件十分严格。它要求系统满足线性叠加原理，同时过程噪声与观测噪声必须服从标准高斯分布。然而真实物理世界中，目标运动普遍呈现高度非线性特征。

为应对上述问题，扩展卡尔曼滤波与无迹卡尔曼滤波等非线性变体相继被提出。扩展卡尔曼滤波借助泰勒级数展开，对非线性系统进行局部一阶线性化截断。无迹卡尔曼滤波则利用无迹变换直接逼近非线性状态的概率密度分布，避免了显式线性化带来的截断误差。以上算法均致力于将实际问题的非线性转变为线性，然而其本质上仍属于纯物理模型驱动范式，其估计性能高度依赖于精确的系统动力学先验方程。

此外，传统滤波器需要预设固定的过程噪声协方差与量测噪声协方差矩阵。然而高机动目标的实际运动轨迹可能发生剧烈的物理突变。这种突变可以导致预设模型参数与真实运动状态之间产生严重的数学失配。固定参数框架难以对目标的非线性动态演变做出及时响应。在复杂场景下，纯模型驱动架构极易引发估计精度的大幅衰减，甚至诱发滤波发散。

1.2.4 人工智能与滤波算法的融合

传统滤波器依赖预设模型，当预设模型与实际系统存在偏差时，会产生截断误差。特别是在面对非线性系统时误差更加显著。对此，以长短期记忆网络（Long Short-Term Memory, LSTM）与门控循环单元（Gated Recurrent Unit, GRU）为代表的时间序列模型，提供了另一种解决思路。这类网络具备强大的时序特征提取能力和历史状态记忆能力。借助此类深度网络，系统可以对目标复杂的非线性运动残差进行隐式建模。数据驱动模块能够对传统滤波器的误差进行实时补偿。该机制客观上可以提高目标在高动态场景下的轨迹预测可靠性。

KalmanNet 正是上述混合架构的一个典型代表。该算法并未采用纯深度学习的端到端黑盒结构，而是严格保留了经典卡尔曼滤波中数学意义明确的状态闭环

更新方程。与此同时，它利用递归神经网络模块，彻底替代了传统算法中基于固定先验协方差矩阵的解析增益计算过程。KalmanNet 仅以当前时刻的观测残差序列作为输入，由网络通过隐式学习动态输出自适应的卡尔曼增益矩阵。这一数据驱动机制使系统能够根据实时量测变化，自动感知底层物理模型的失配程度。得益于这种设计，该混合架构使滤波系统摆脱了对精确过程噪声与量测噪声先验统计分布的强依赖，从而在非线性运动场景下获得了更鲁棒的状态估计能力[2]。

因此，将 KalmanNet 集成至 ByteTrack 的运动学关联框架中是一条可行的技术路线。

1.3　论文研究工作及安排

本文研究内容主要为构建一种融合深度学习与经典滤波理论的混合估计系统。

本文选择导弹作为研究对象，采用多目标跟踪算法对导弹状态进行估计。具体实现方法为利用 YOLOX 算法实现前端目标检测；基于 ByteTrack 算法完成多目标跟踪。并在 ByteTrack 算法中引入 KalmanNet 辅助标准卡尔曼滤波进行轨迹预测。KalmanNet 通过提取新息残差（F_2）与状态更新差值（F_4）输出卡尔曼增益的修正值来辅助标准卡尔曼滤波，从而降低对 $\boldsymbol{Q}$、$\boldsymbol{R}$ 矩阵人工设定敏感性。

本文旨在实现稳定跟踪导弹目标，并提升 ByteTrack 算法的跟踪性能。本文共分为五个章节。各章节具体研究工作安排如下：

第一章是绪论部分，对融合神经网络和卡尔曼滤波的混合模型状态估计的研究目的和意义进行了阐述。并且对跟踪导弹目标的意义内容进行了阐述，此外分析了多目标跟踪算法的国内外研究现状并对各种多目标跟踪范式的特点进行了介绍，最后阐述了在导弹目标跟踪问题中运用融合神经网络和卡尔曼滤波进行状态估计的可行性。最后交代了本文的研究工作以及工作内容的安排。

第二章介绍相关理论基础。分别介绍了 YOLOX 检测器原理、ByteTrack 算法流程以及标准卡尔曼滤波数学模型。

第三章介绍对 ByteTrack 算法的改进。该章节将论述 KalmanNet 的网络架构、训练策略、损失函数设计、输入特征组合等内容。并且阐述如何将 KalmanNet 融合进 ByteTrack 算法框架中，并且介绍系统的数据流处理逻辑。

第四章介绍与分析实验结果。介绍本文实验环境设置，改进算法在测试数据集上的性能表现与利用测试数据集评估目标检测精度与关联效果。内容对比不同算法下高阶跟踪精度（Higher Order Tracking Accuracy, HOTA）与身份识别分数（IDF1）

等核心指标。此外实验数据证明混合模型对非线性机动具有较强自适应能力。相应地结果验证建立模型合理性。

第五章归纳全文研究工作。梳理本文算法和模型的不足。

第二章　相关理论与技术基础

2.1　YOLOX 算法原理

视觉跟踪任务首先依赖于高性能的前端检测器的检测。本文使用 YOLOXv8 作为前端检测器，其作为 YOLO 系列的重要改进版本，通过引入解耦头（Decoupled Head）与无锚框（Anchor-free）机制，显著提升了复杂背景下目标的检测精度与推理速度。

2.1.1　解耦头设计

传统目标检测器的检测头通常将分类与定位任务耦合在同一特征层中进行预测，但这两种任务所关注的特征存在固有的冲突。YOLOX 通过解耦头结构将两路特征分离，分别预测类别概率和边界框坐标。这种结构不仅加快了模型的收敛速度，更在应对导弹这类在三维空间中姿态多变的精细目标时，展现出更高的检测敏感度与准确率。

2.1.2　无锚框与 SimOTA 策略

传统的基于锚框（Anchor-based）的算法需要预设大量的先验框，这在面对尺度变化剧烈的高机动目标时具有很大的局限性。YOLOX 采用无锚框机制，直接预测图像像素点到目标边界框边缘的偏移量，极大地减少了模型超参数的数量。同时，配合 SimOTA（Simplified Optimal Transport Assignment）动态标签分配策略，模型能够根据目标的实际重叠情况自适应地选择正样本，有效抑制了远距离小目标的漏检现象。

2.2　ByteTrack 算法流程

如第一章所述，本文在多目标跟踪的三类范式中选择了分离检测与特征提取的 SDE 框架，并确定以 ByteTrack 作为基础算法。

2.2.1　ByteTrack 算法流程描述

ByteTrack 算法核心创新在于提出 BYTE 数据关联算法。该算法摒弃了直接丢弃低置信度检测框的传统做法。算法的完整流程为, 第一步根据预设阈值将当前帧所有检测框划分为高置信度与低置信度两组; 随后系统利用卡尔曼滤波对现有轨迹进行状态预测。第二步通过计算预测结果与高置信度检测框之间相似度完成首次关联。并且系统将针对首次关联后剩余失配轨迹与低置信度检测框进行二次匹配。最终系统利用匹配成功检测框观测值更新轨迹状态。未匹配高置信度检测框

被初始化为新轨迹。长时间未匹配轨迹则被剔除。流程如图 2.1所示

Algorithm 1: Pseudo-code of BYTE.

Input: A video sequence V; object detector Det; detection score threshold τ
Output: Tracks $\mathcal{T}$ of the video

```
Initialization: T ← ∅
for frame f_k in V do
    /* Figure 2(a) */
    /* predict detection boxes & scores */
    D_k ← Det(f_k)
    D_high ← ∅
    D_low ← ∅
    for d in D_k do
        if d.score > τ then
            D_high ← D_high ∪ {d}
        end
        else
            D_low ← D_low ∪ {d}
        end
    end

    /* predict new locations of tracks */
    for t in T do
        t ← KalmanFilter(t)
    end

    /* Figure 2(b) */
    /* first association */
    Associate T and D_high using Similarity#1
    D_remain ← remaining object boxes from D_high
    T_remain ← remaining tracks from T

    /* Figure 2(c) */
    /* second association */
    Associate T_remain and D_low using similarity#2
    T_re-remain ← remaining tracks from T_remain

    /* delete unmatched tracks */
    T ← T \ T_re-remain

    /* initialize new tracks */
    for d in D_remain do
        T ← T ∪ {d}
    end
end
Return: T
```

图 2.1 ByteTrack 算法伪代码

2.2.2 算法与卡尔曼滤波的关系

在数据关联之前，ByteTrack 首先调用卡尔曼滤波的预测步。算法利用上一时刻的后验估计，推算出当前时刻轨迹的先验位置。这一预测结果在关联阶段起着关键作用。具体而言，算法将利用卡尔曼滤波输出的先验预测框与实际检测框之间的 IoU 距离来进行轨迹匹配。当目标发生短暂遮挡、检测器暂时失效时，卡尔曼滤波仍能依靠历史运动惯性，给出轨迹的预估位置。匹配完成后，关联结果会

选取最优检测值作为观测输入，回传至卡尔曼滤波的更新步，对轨迹状态向量进行实时修正。

综上所述，卡尔曼滤波为 ByteTrack 提供时序运动先验，而 ByteTrack 算法的数据关联依赖卡尔曼滤波的预测。

2.3　经典状态估计理论

卡尔曼滤波 KF 是目标跟踪领域的核心状态估计算法，其在最小均方误差准则下，通过递归的“预测-更新”过程实现对系统状态的最优估计。

2.3.1　数学模型描述

设系统在 t 时刻的状态向量为 $\boldsymbol{x}_t$，量测向量（观测向量）为 $\boldsymbol{z}_t$。系统的离散线性状态空间模型定义如下：

$$\boldsymbol{x}_t = \boldsymbol{F}\boldsymbol{x}_{t-1} + \boldsymbol{w}_{t-1} \tag{2-1}$$

$$\boldsymbol{z}_t = \boldsymbol{H}\boldsymbol{x}_t + \boldsymbol{v}_t \tag{2-2}$$

式中，$\boldsymbol{F}$ 为状态转移矩阵；$\boldsymbol{H}$ 为量测矩阵；$\boldsymbol{w}_{t-1}$ 与 $\boldsymbol{v}_t$ 分别为系统过程噪声和量测噪声，通常假设二者均为零均值的高斯白噪声。

2.3.2　递归滤波过程

标准卡尔曼滤波的计算过程分为预测与更新两个独立阶段：

1. 预测阶段（时间更新）：

利用上一时刻的后验状态估计推算当前的先验状态估计与误差协方差：

$$\hat{\boldsymbol{x}}_{t|t-1} = \boldsymbol{F}\hat{\boldsymbol{x}}_{t-1|t-1} \tag{2-3}$$

$$\boldsymbol{P}_{t|t-1} = \boldsymbol{F}\boldsymbol{P}_{t-1|t-1}\boldsymbol{F}^T + \boldsymbol{Q} \tag{2-4}$$

式中，$\boldsymbol{P}$ 为估计误差协方差矩阵；$\boldsymbol{Q}$ 为过程噪声协方差矩阵。

2. 更新阶段（量测更新）：

结合当前的实际量测值对先验估计进行修正，以获得最优后验估计：

$$\boldsymbol{K}_t = \boldsymbol{P}_{t|t-1}\boldsymbol{H}^T(\boldsymbol{H}\boldsymbol{P}_{t|t-1}\boldsymbol{H}^T + \boldsymbol{R})^{-1} \tag{2-5}$$

$$\hat{\boldsymbol{x}}_{t|t} = \hat{\boldsymbol{x}}_{t|t-1} + \boldsymbol{K}_t(\boldsymbol{z}_t - \boldsymbol{H}\hat{\boldsymbol{x}}_{t|t-1}) \tag{2-6}$$

$$\boldsymbol{P}_{t|t} = (\boldsymbol{I} - \boldsymbol{K}_t\boldsymbol{H})\boldsymbol{P}_{t|t-1} \tag{2-7}$$

式中，$\boldsymbol{K}_t$ 为卡尔曼增益矩阵；$\boldsymbol{R}$ 为量测噪声协方差矩阵；$\boldsymbol{I}$ 为单位矩阵。

2.3.3 传统算法的局限性分析

标准卡尔曼滤波在处理高机动导弹目标时存在客观局限。导弹的空间运动具有显著的非线性特征，难以用标准线性方程精确建模。传统卡尔曼滤波本质上属于纯模型驱动算法，其估计性能高度依赖系统状态空间模型的精确构建。此外，该算法要求预先设定精确的过程噪声协方差矩阵 Q 与量测噪声协方差矩阵 R。在复杂空间环境下，目标观测噪声的统计特性往往未知且随时间变化。固定的 Q、R 矩阵极易偏离目标的真实物理动态。这导致卡尔曼增益无法根据环境变化进行自适应更新，跟踪精度随之衰减，甚至可能引发滤波发散。

上述缺陷的根源在于传统算法的增益计算逻辑。经典滤波器完全依赖预设的协方差矩阵来推导卡尔曼增益，系统缺乏基于实时观测残差进行动态修正的能力。如若引入深度神经网络来处理历史观测残差序列，网络通过隐式学习直接输出自适应动态增益，就能降低卡尔曼滤波的误差。KalmanNet 的网络拓扑设计、训练策略以及与 ByteTrack 关联框架的协同融合机制，将在第三章展开详细论述。

第三章　融合神经网络与滤波的算法设计

3.1　系统总体架构设计

高机动导弹目标在复杂对抗环境中表现出强非线性与高动态特性。传统纯模型驱动状态估计算法高度依赖预设线性动力学模型。目标面对变轨机动时系统极易产生模型失配。基于此，本文构建了融合物理先验与数据驱动的混合跟踪体系。

系统总体由目标检测与目标跟踪两个核心模块构成。系统数据流为，首先视频流图像帧输入至 YOLOX 前端检测器，系统提取目标边界框观测信息与检测置信度；随后 ByteTrack 框架利用二次匹配逻辑进行数据关联。

在上述流程中本文对关联过程进行了改进，引入 KalmanNet 辅助标准线性卡尔曼滤波。

KalmanNet 保留卡尔曼滤波中物理意义明确预测与更新一阶矩推算流程，并且利用递归神经网络隐式计算卡尔曼增益修正量。该架构能在步破坏系统运动学先验的前提下，提高模型对非线性目标的跟踪性能。

3.2　KalmanNet 状态估计网络设计

3.2.1　多维输入特征提取

KalmanNet 的核心创新在于利用神经网络替代传统卡尔曼滤波中固定的增益计算逻辑，网络需从输入数据中感知系统当前的状态与模型偏差。因此网络的输入特征应该为网络提供能够表征当前模型失配程度与目标运动趋势的有效信息。并且，此类特征并非人工构造的抽象统计量，而是直接从滤波流程中提取的中间变量。它们需要具备明确的物理含义，并且无需引入额外计算即可获得。

KalmanNet 所采用的输入特征由以下四类差分特征构成。

第一类特征为观测量差值（F_1），定义为相邻两帧之间实际观测值的瞬时变化量：

$$F_1 = \boldsymbol{z}t - \boldsymbol{z}t - 1 \tag{3-1}$$

第二类特征为新息残差（F_2），定义为当前时刻实际观测值与先验观测预测值之间的偏差。该特征是评估模型失配程度的核心指标：

$$F_2 = \boldsymbol{z}t - \boldsymbol{H}\hat{\boldsymbol{x}}t|t - 1 \tag{3-2}$$

第三类特征为状态演化差值（F_3），定义为相邻两帧之间状态后验估计值的变

化量，用于表征目标状态的时序演化规律：

$$F_3 = \hat{\boldsymbol{x}}t|t - \hat{\boldsymbol{x}}t - 1|t - 1 \tag{3-3}$$

第四类特征为状态更新差值（F_4），定义为同一时刻状态后验估计值相对于先验预测值的修正量：

$$F_4 = \hat{\boldsymbol{x}}t|t - \hat{\boldsymbol{x}}t|t - 1 \tag{3-4}$$

上述四类特征均直接来源于卡尔曼滤波的递归计算过程，具备明确的物理含义，且无需额外计算开销。

F_1 与 F_2 侧重于描述测量层面的不确定性；F_3 与 F_4 包含状态演化层面的修正信息。本文将在实验阶段对不同特征组合进行实验，从而选择最合适的输入特征组合。

3.2.2 网络架构选择与设计

在网络结构探索方面，本文考虑了两种计算卡尔曼增益的 RNN 架构：一种是隐藏状态容量较大的单层隐式跟踪架构；另一种是由三个门控循环单元（Gated Recurrent Unit, GRU）层组成的解耦跟踪架构，分别追踪状态噪声协方差矩阵、预测协方差矩阵及残差协方差矩阵。

基于这两种基础架构，本文考虑了两种不同的 GRU 网络架构。架构一采用单层 GRU 完全替代传统卡尔曼滤波参数推算流程。架构二采用解耦设计并利用三层 GRU 分别追踪不同的协方差矩阵。架构细节如图 4.1所示。

架构一与架构二均采用直接增益输出策略，将在下一小节中统一说明。此外，本文在架构二的基础上进一步修改了网络输出策略，形成架构三，具体内容将在下一小节中详细介绍。

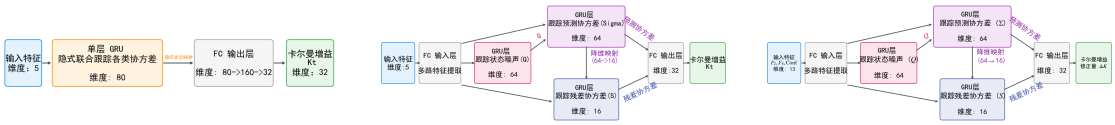

(a) 架构一框架图 (b) 架构二框架图 (c) 架构三框架图

图 3.1 不同网络架构框架图

3.2.3 网络输出

本文考虑了两种 KalmanNet 算法的网络输出形式。

第一种，网络直接输出完整卡尔曼增益矩阵。该网络保留了传统卡尔曼滤波一阶矩计算架构，计算过程包含状态预测、状态更新与输出完整卡尔曼增益三个核心步骤，如式 (3-5)、式 (3-6) 与式 (3-7) 所示：

$$\hat{\boldsymbol{x}}_{t|t-1} = \boldsymbol{F}\hat{\boldsymbol{x}}_{t-1|t-1} \tag{3-5}$$

$$\hat{\boldsymbol{x}}_{t|t} = \hat{\boldsymbol{x}}_{t|t-1} + \boldsymbol{K}_t\left(\boldsymbol{y}_t - \boldsymbol{H}\hat{\boldsymbol{x}}_{t|t-1}\right) \tag{3-6}$$

$$\boldsymbol{K}_t = \mathrm{RNN}(\Delta\boldsymbol{y}_t, \Delta\tilde{\boldsymbol{y}}_t, \Delta\tilde{\boldsymbol{x}}_t, \Delta\hat{\boldsymbol{x}}_t) \tag{3-7}$$

式中 $\hat{\boldsymbol{x}}_{t|t-1}$ 与 $\hat{\boldsymbol{x}}_{t|t}$ 为 t 时刻先验状态预测值与后验状态估计值。$\boldsymbol{F}$ 为状态转移矩阵；$\boldsymbol{H}$ 为观测矩阵；$\boldsymbol{y}_t$ 为当前帧观测向量。$\boldsymbol{K}_t$ 为完整卡尔曼增益矩阵；$\Delta\boldsymbol{y}_t$ 为新息差值；$\Delta\tilde{\boldsymbol{y}}_t$ 为新息残差；$\Delta\tilde{\boldsymbol{x}}_t$ 为前向烟花差值；$\Delta\hat{\boldsymbol{x}}_t$。$\boldsymbol{\theta}$ 为前向更新差值

第二种，网络输出卡尔曼增益的修正值。系统首先依据预设过程噪声协方差矩阵 $\boldsymbol{Q}$ 与量测噪声协方差矩阵 $\boldsymbol{R}$ 计算卡尔曼增益 $\boldsymbol{K}_{t,\mathrm{c}}$，如式 (3-8) 所示：

$$\boldsymbol{K}_{t,\mathrm{c}} = \boldsymbol{\Sigma}_{t|t-1}\boldsymbol{H}^{\mathrm{T}}(\boldsymbol{H}\boldsymbol{\Sigma}_{t|t-1}\boldsymbol{H}^{\mathrm{T}} + \boldsymbol{R})^{-1} \tag{3-8}$$

随后循环神经网络基于输入特征生成卡尔曼修正值 $\Delta\boldsymbol{K}_t$，如式 (3-9) 所示：

$$\Delta\boldsymbol{K}_t = \mathrm{RNN}(\Delta\boldsymbol{y}_t, \Delta\tilde{\boldsymbol{y}}_t, \Delta\tilde{\boldsymbol{x}}_t, \Delta\hat{\boldsymbol{x}}_t) \tag{3-9}$$

系统最终卡尔曼增益如式 (3-10) 所示：

$$\boldsymbol{K}_t = \boldsymbol{K}_{t,\mathrm{c}} + \Delta\boldsymbol{K}_t \tag{3-10}$$

上一小节介绍的架构中，架构一与架构二侧重利用深度学习网络直接取代传统卡尔曼滤波，系统直接通过纯数据驱动方式学习目标运动规律；架构三则为保留卡尔曼滤波递归结构基础上，利用神经网络对卡尔曼增益进行残差修正。以上三种架构的结构分布如图 4.1所示。

3.3　损失函数设计与模型训练策略

3.3.1　损失函数

在实际应用系统的最优卡尔曼增益真值难以获取，因此 KalmanNet 无法进行直接的监督学习。基于此本文采用基于最终状态估计的误差来监督 KalmanNet 训练。以最终状态后验估计值与真实标签值之间的均方差作为损失函数，如式 (3-11)所示。

$$\mathcal{L}_t = \left\| \hat{\boldsymbol{x}}_{t|t} - \boldsymbol{x}_t^{GT} \right\|_2^2 \tag{3-11}$$

式中 $\hat{\boldsymbol{x}}_{t|t}$ 为最终状态后验估计值；$\boldsymbol{x}_t^{GT}$ 为真实标签值

3.3.2 训练策略

在随时间反向传播训练过程中，序列长度的选择会直接影响模型的收敛稳定性与学习效果。

一种策略是直接使用完整的长视频序列进行训练。其优点在于能够充分保留目标在时间维度上的长程依赖关系，有助于网络学习长期运动模式与身份一致性。然而，过长的序列在反向传播时容易引发梯度消失或梯度爆炸，训练过程中损失函数可能出现剧烈震荡，模型收敛难度较大。

另一种策略是仅使用固定长度的短轨迹片段进行截断训练。该策略通过限制序列长度，有效规避了梯度消失与爆炸的风险，使网络能够快速稳定收敛，并学会基础的时序修正能力。但缺点在于，短片段训练难以覆盖目标的长期运动依赖关系，网络对长周期身份一致性的建模能力相对有限，可能影响身份识别相关指标的表现。

为兼顾上述两种策略的优势，可以考察使用由短及长的两阶段递进式训练策略。即在第一阶段采用短序列进行截断训练，快速稳定网络权重。并在网络初步收敛后进入第二阶段，引入完整长序列进行训练，增强网络学习对遮挡等复杂场景的适应能力。关于本文具体采用的训练策略及其效果，将在实验章节中详细讨论。

第四章　实验结果与分析

4.1　实验环境与数据集

本实验基于 Windows 平台通过 Python 语言实现，采用 Windows 11 操作系统，深度学习框架为 Pytorch 2.5.1，采用 CUDA 12.1 和 cuDNN 8.9 加速训练；所运行的硬件平台如下：处理器为 AMD Ryzen 7 5800H，显卡为 NVIDIA RTX 3060。

高机动导弹真实飞行视觉数据属于高度机密且极难获取。目前缺乏公开的、具有认可度的并且具有精确标注轨迹的导弹数据集。缺乏数据集难以训练深度神经网络。本文注意到多目标跟踪领域经典公开数据集 MOT17，该数据集包含大量复杂遮挡与目标交错的场景，这些场景能够检验跟踪算法基础状态估计与数据关联能力。基于此，本文首先在 MOT17 数据集上开展有效性验证实验，先通过该基准验证混合驱动架构的底层逻辑。

多目标跟踪算法的评价常使用官方测试集进行在线评估，该评估需要登录 Motchallenge 网站。由于本文目前无法获取该平台的在线评测权限，故采用当前普遍认可的离线拆分训练集的方法来获取系统性能数据。该方法是将官方训练集视频序列按时间帧对半划分，采用每个视频序列前半部分进行模型训练，并利用后半部分开展性能验证。本文将严格遵循 MOT17half 划分方式开展后续实验。

4.2　评价指标

为科学量化算法性能, 本文选取多目标跟踪领域国际通用指标进行评估, 评价标准如表 4.1 所列。

4.3　实验结果与分析

4.3.1　GRU 架构选择

在网络结构探索方面，本文考虑了两种计算卡尔曼增益的 RNN 架构：一种是隐藏状态容量较大的单层隐式跟踪架构；另一种是由三个门控循环单元（Gated Recurrent Unit, GRU）层组成的解耦跟踪架构，分别追踪状态噪声协方差矩阵、预测协方差矩阵及残差协方差矩阵。

基于这两种基础架构，本文设计了三种不同的 GRU 网络架构。架构 1 采用单层 GRU 完全替代传统卡尔曼滤波参数推算流程。架构 2 采用解耦设计并利用三层 GRU 分别追踪不同的协方差矩阵。架构 3 保留卡尔曼滤波基础数学框架并利用三

表 4.1 多目标跟踪指标含义

评价指标	定义
HOTA (↑)	综合衡量检测与关联精度
MOTA (↑)	综合衡量漏检误报与身份切换
IDF1 (↑)	评估全局轨迹身份一致性
DetA (↑)	衡量单帧目标定位精度
AssA (↑)	衡量跨帧身份匹配精度
Recall (↑)	真实目标检出比例
Precision (↑)	检测结果正确比例
IDP (↑)	预测轨迹分配正确身份比例
IDR (↑)	真实轨迹分配正确身份比例
IDSW (↓)	目标身份标识切换总次数
FP (↓)	背景误判为目标总次数
FN (↓)	真实目标漏检总次数
MT (↑)	连续跟踪时长超 80% 目标占比
PT	连续跟踪时长介于 20% 至 80% 目标占比
ML (↓)	连续跟踪时长低于 20% 目标占比

层 GRU 输出残差以修正卡尔曼增益。以上三种架构的结构分布如图 4.1所示。

为客观对比不同架构的性能，本文在一致的实验条件下对三种网络分别开展 60 轮训练。所有实验均在相同软硬件环境运行，系统硬件采用 NVIDIA RTX 3060 显卡；软件框架均采用 PyTorch 2.5.1。固定随机种子为 42，以保证训练数据生成与验证集划分完全一致；统一采用 Adam 优化器并搭配余弦退火学习率衰减策略；此外，设置初始学习率为 1×10^{-3}，最小学习率为 1×10^{-5}。三种架构均采用相同时间步长与训练策略。

在训练策略方面，实验均采用了相同的短序列时间反向传播（Short BPTT）策略，时间步长（Sequence Length）固定为 20 帧。

性能对比结果如图图 4.2 所示。实验结果表明架构三在该条件下性能最优，其综合指标 HOTA 达到 68.18%，明显优于架构一的 64.00% 和架构二的 65.07%。

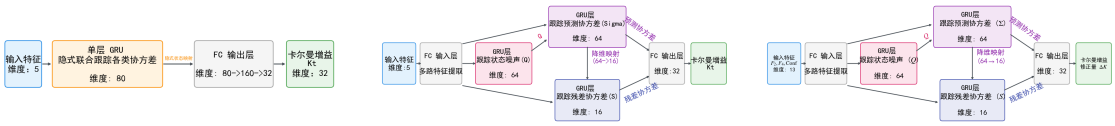

(a) 架构一框架图　　(b) 架构二框架图　　(c) 架构三框架图

图 4.1　不同网络架构框架图

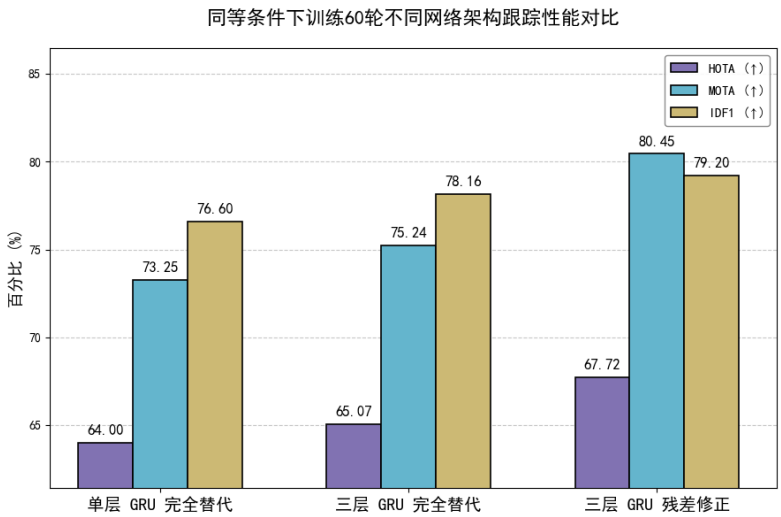

图 4.2　不同架构训练 60 轮性能对比图

4.3.2　训练策略分析

在深度学习中，训练序列长度会直接影响循环神经网络长程记忆保持能力，基于此本节将对比不同架构在使用不同长度训练序列时的性能变化。

等待修改常规方法通常采用短轨迹窗口更新网络参数，这有利于收敛，但在实际场景中面对高频遮挡时，记忆容量不足常常导致目标身份切换。基于此，我们引入了一种长短轨迹片段混合训练的方式，专门考察序列长度对纯数据驱动架构和物理启发架构的不同影响。

图 4.3 表明架构一与架构二在引入长片段进行训练后的指标变话，均出现显著的性能退化。这两种架构都保留了一定的运动学模型，包括但不限于物理先验和观测残差。但由于两种架构均使用神经网络负责输出完整的卡尔曼增益，当模型处理长片段、强遮挡的复杂轨迹时，短时的高强度噪声容易诱发神经网络输出极端增益值，导致系统误差发送累积，最终引发轨迹发散。

此外图 4.4 表明架构三在引入长片段训练后性有所上升。该架构仍保有卡尔曼滤波的数学框架，模型仅利用神经网络来修正卡尔曼增益。该机制保证了模型

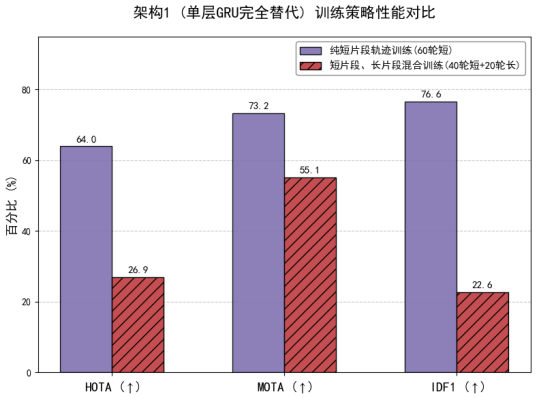

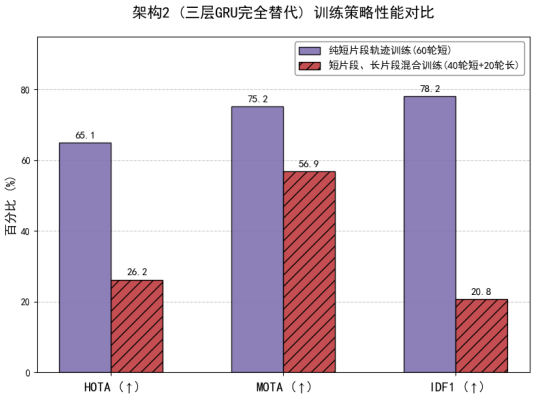

(b) 架构 1 在不同训练策略下模型的性能表现　　(a) 架构 2 在不同训练策略下模型的性能表现

图 4.3　两种架构在混合训练中的性能退化现象

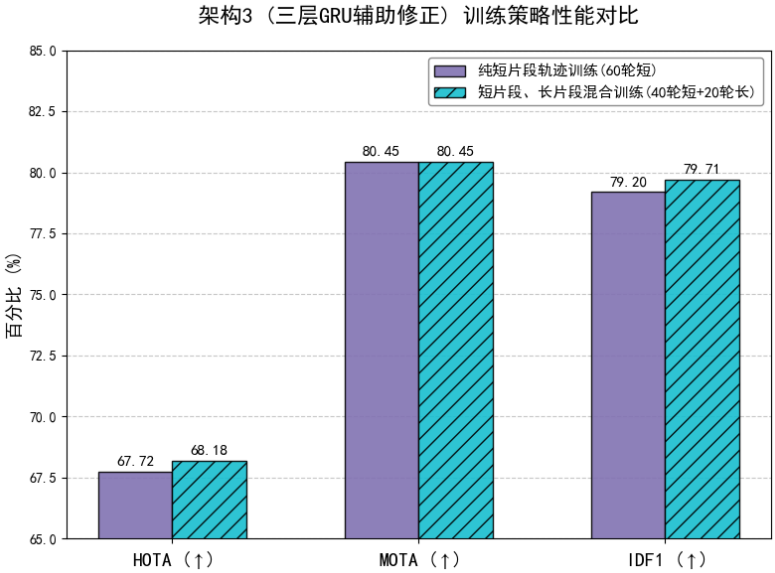

图 4.4　架构 3 在不同训练策略下模型的性能表现

在长片段、强遮挡的条件下依能维持稳定的轨迹预测。

如图 4.5(a) 所示，架构三在混合训练策略下的损失下降曲线更优。由于两种策略的短片段训练长度不同，导致余弦退火学习率衰减周期设置不同，从而使得短片段训练的前 40 轮损失下降低于长短片段混合训练的损失下降曲线。此外在相同的总训练轮次下，混合训练策略的损失收敛值更低。并且如图 4.5(b) 所示，架构三在混合训练策略中的模型跟踪性能指标 HOTA 更高。因此，本文确定采用架构三的混合训练策略。

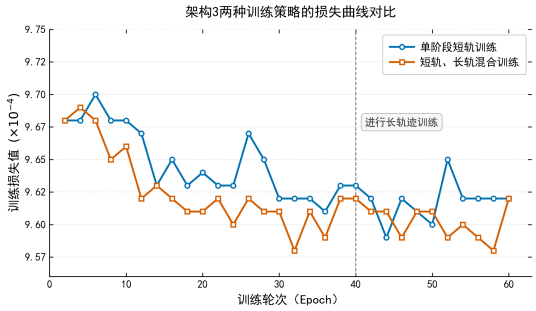

(a) 架构 3 不同训练曲线的损失曲线对比

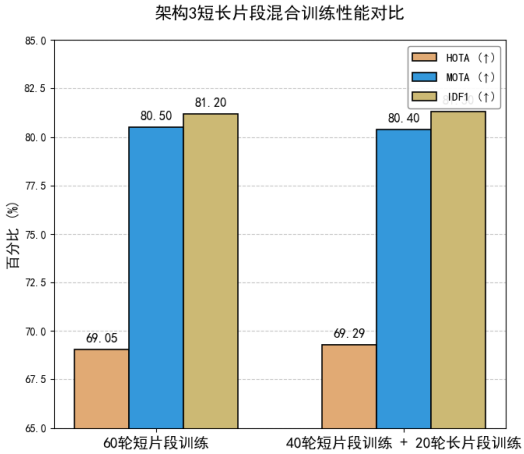

(b) 架构 3 长短片段混合训练性能对比

图 4.5　架构 3 长短片段混合训练策略评估

4.3.3　输入特征组合消融实验

输入特征选取直接决定神经网络感知系统动态失配程度的精准度，进而影响卡尔曼增益修正的准确性。有大量经验表明，具体的输入特征组合取决于具体的问题，并且有经验表明常用输入特征组合为F_1，F_2，F_4 和F_1，F_3，F_4。。因此本文设定了输入特征消融实验来确定模型的输入特征组合。

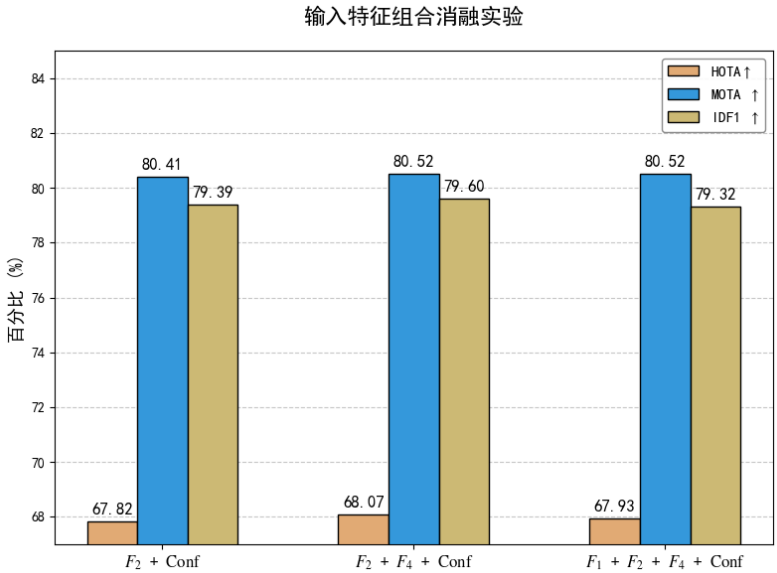

图 4.6　输入特征组合消融实验

如图 4.6 所示。实验数据表明新息残差 F_2 和状态更新差值 F_4 组合性能略微高于其他组合。该组合精准保留核心物理失配信息并有效抑制外部干扰。本文发现引入观测残差 F_1 反而造成各项评估指标全方位降低。

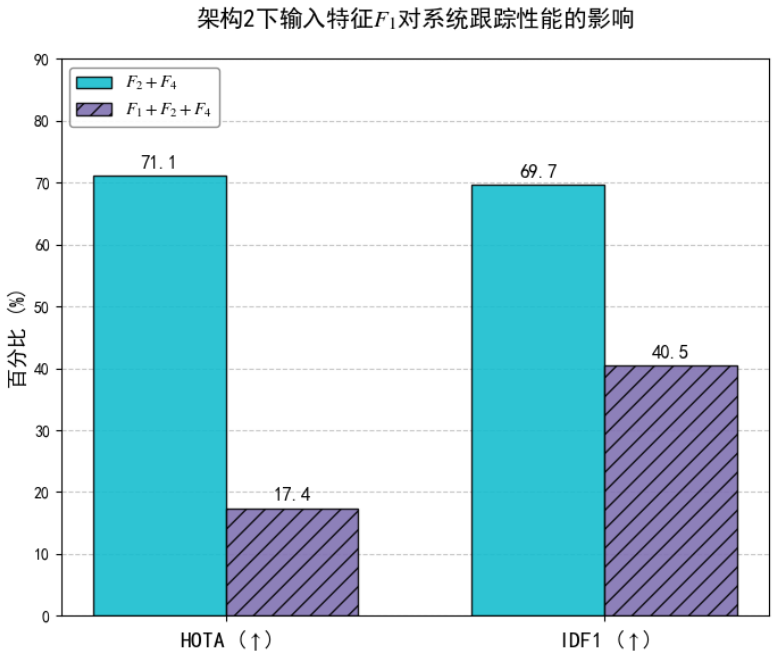

图 4.7 架构 2 下输入特征 F_1 对系统跟踪性能的影响

为深入探究该现象系统在敏感度更高架构 2 中单独测试 F_1 特征影响。图 4.7 清晰展示包含 F_1 后系统性能发生断崖式暴跌。分析认为观测残差 F_1 直接来源于相邻两帧前端检测框坐标差值。该特征包含大量视觉检测器引入高频随机噪声。严重噪声直接干扰网络内部隐状态更新过程。系统剔除 F_1 能够促使模型专注学习系统级物理状态偏差。相应地本文最终确立 F_2 与 F_4 组合作为标准输入特征。

4.3.4 模型对比与分析

本文综合对比主流算法基准与改进方案测试数据。表 4.2 列举当前多目标跟踪领域主流算法在 MOT17 数据集上的性能指标数据。表 4.3 展示了本文改进模型的评价指标数据。实验数据证明改进算法取得优异综合性能。

本文改进模型的 HOTA 指标相较于基础算法 ByteTrack 的提高了 5.08%，因此可以证明，本文的改进客观提升了原算法的高精度检测与稳定关联能力。

在复杂遮挡场景下，系统通过神经网络输出卡尔曼残差增益，并在经典卡尔曼增益的基础上进行非线性修正。该机制，使得网络在观测缺失时能够依托物理先验维持状态推演，在观测恢复时迅速实现轨迹匹配。该机制抑制了强遮挡下的身份丢失现象，系统跨帧身份匹配精度 AssA 达到 68.55%。并且与原算法相比，本文模型在全局轨迹身份一致性指标 IDF1 的上也有所提高，IDF1 达到 79.71%。

表 4.2　MOT17 测试集各主流跟踪算法性能对比

Method	**MOTA** (↑)	**IDF1** (↑)	**HOTA** (↑)	**FP** (↓)	**FN** (↓)	**IDs** (↓)
TransCenter	73.2	62.2	54.5	23112	123738	4614
FairMOT	73.7	72.3	59.3	27507	117477	3303
RelationTrack	73.8	74.7	61.0	27999	118623	1374
CSTrack	74.9	72.6	59.3	23847	114303	3567
TransTrack	75.2	63.5	54.1	50157	86442	3603
SiamMOT	76.3	72.3	-	-	-	-
CorrTracker	76.5	73.6	60.7	29808	99510	3369
TransMOT	76.7	75.1	61.7	36231	93150	2346
MAATrack	79.4	75.9	62.0	37320	77661	1452
OCSORT	78.0	77.5	63.2	15129	107055	1950
MOTRV2	78.6	75.0	62.0	23409	94797	2619
StrongSORT++	79.6	79.5	64.4	27876	86205	1194
ByteTrack	80.3	77.3	63.1	25491	83721	2196
Bot-SORT	80.5	80.2	65.0	22521	86037	1212
UCMCTrack	79.0	79.0	64.3	-	-	-
Deep OC-SORT	79.4	80.6	64.9	16600	98800	1023
FeatureSORT	80.6	76.7	64.2	27581	84362	2637
BoostTrack++	80.7	82.2	66.6	-	-	-
SparseTrack	81.0	80.1	65.1	23904	81927	1170
C-BIoU	81.1	79.7	64.1	-	-	-
MotionTrack	81.1	80.1	65.1	23802	81660	1140
SMILEtrack	81.1	80.5	65.3	22963	79428	1246

表 4.3 改进算法在 MOT17half 验证集性能指标

Method	**HOTA** (↑)	**DetA** (↑)	**AssA** (↑)	**MOTA** (↑)	**IDF1** (↑)	**IDP** (↑)	**IDR** (↑)
ours	68.18%	68.58%	68.55%	80.45%	79.71%	84.92%	75.11%

Method	**Recall** (↑)	**Prec** (↑)	**IDSWs** (↓)	**FP** (↓)	**FN** (↓)	**MT** (↑)	**PT**	**ML** (↓)
ours	84.63%	95.69%	195	2055	8283	197	103	39

4.4 YOLOX 检测器训练结果

检测器位于跟踪流程最前端，其输出质量直接决定后续数据关联与滤波环节的可靠性。因此，本节介绍 YOLOX 检测器的训练数据与评估结果。本文利用公开导弹图片数据集与虚幻引擎 4 仿真图像，制作了包含 1646 张图片的导弹数据集，如图 4.8所示。

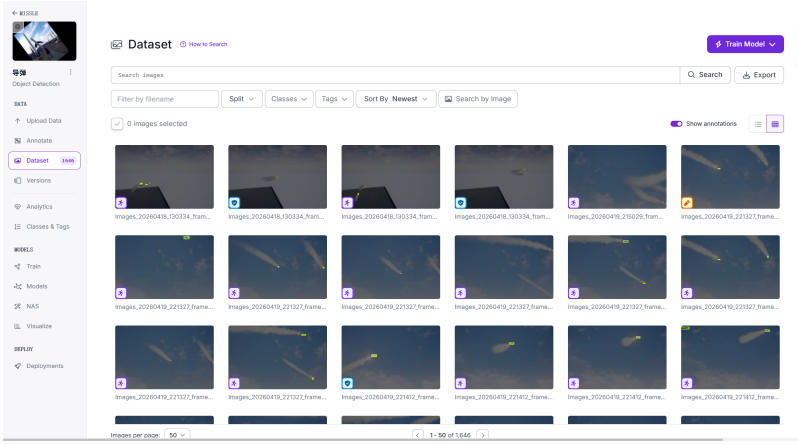

图 4.8 导弹数据集

基于该数据集完成 YOLOX 检测器训练后，评估结果如图 4.9所示。YOLOX 检测器交并比阈值 0.5 下的平均精度达到 87.1%，平均精度均值也达到 50.0%。该模型能够有效抑制背景噪声干扰。此外模型对不同尺度目标响应存在显著差异，这导致了检测器整体平均召回率 AR 维持在 59.2%。系统在远场小目标或严重遮挡条件下容易存在漏检现象。

4.5 导弹数据集跟踪性能评估与效果展示

本文基于虚幻引擎 4 搭建了 AirSim 导弹飞行仿真平台，该工程可以生成导弹飞行仿真图片与导弹飞行仿真视频，分别用于训练 YOLOX 前端检测器和训练多目标跟踪算法模型。

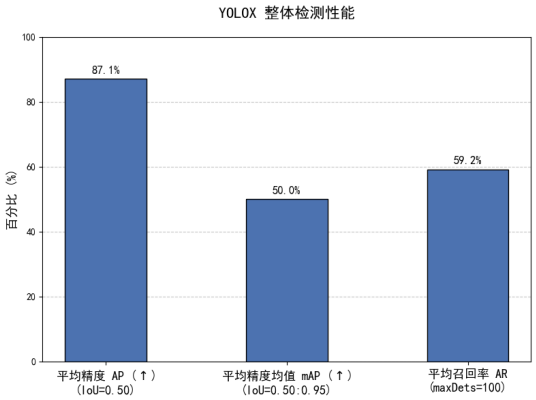

(a) yolox 整体精度

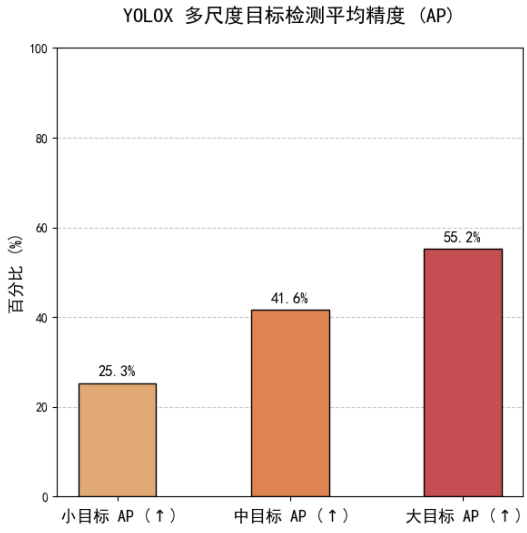

(b) yolox 不同尺寸目标识别精度

图 4.9　YOLOX 检测器训练评估结果

仿真规则为导弹飞行路径通过多阶贝塞尔曲线生成基础飞行路径，并且可以通过设置时空约束点，强制多枚导弹在相机视角下产生交汇、遮挡和重叠场景。

为增强后续跟踪算法的跟踪能力，需要观测数据包含一定的置信度梯度与视觉扰动，因此本文采用了以下手段进行数据处理。

仿真平台记录了每一枚导弹在图像中位置的绝对真值，为复现正常检测过程中的漏检现象，本文以 10% 概率完全丢弃某帧检测结果；并且未来模拟真实的运动模糊或分辨率受限情况下检测框的定位漂移，本文还对检测框坐标的四个分量分别叠加不同程度高斯白噪声；并对检测框随机赋予 0.6 至 0.95 区间随机置信度。

致　谢

参考文献

[1] 周池军, 邵雷, 骆长鑫, 等. 高动态目标拦截弹制导与控制前沿技术展望[J/OL]. 空天技术, 2022(2): 61-74 [2026-04-30]. https://doi.org/10.16338/j.issn.2097-0714.20220614. DOI: 10.16338/j.issn.2097-0714.20220614.

[2] REVACH G, SHLEZINGER N, NI X, et al. KalmanNet: Neural Network Aided Kalman Filtering for Partially Known Dynamics[J/OL]. IEEE Transactions on Signal Processing, 2022, 70: 1532-1547 [2025-11-08]. https://ieeexplore.ieee.org/document/9733186/. DOI: 10.1109/TSP.2022.3158588.

[3] ZHANG Y, SUN P, JIANG Y, et al. ByteTrack: Multi-Object Tracking by Associating Every Detection Box[EB/OL]. (2022-04-07) [2025-11-24]. http://arxiv.org/abs/2110.06864. arXiv: 2110.06864 [cs]. Pre-published.

[4] 罗元, 肖航, 欧俊雄. 基于深度学习的目标跟踪技术的研究综述[J/OL]. 半导体光电, 2020, 41(6): 757-767 [2026-04-30]. https://doi.org/10.16818/j.issn1001-5868.2020.06.001. DOI: 10.16818/j.issn1001-5868.2020.06.001.